

OPTIMASI DEEP NEURAL NETWORK UNTUK PREDIKSI
HARGA SAHAM DENGAN KATEGORI FLUKTUASI MENENGAH



TESIS

DWI ANDRIYANTO

NIM. 14002432

Program Studi Ilmu Komputer (S2)
Universitas Nusa Mandiri
Jakarta
2022

HALAMAN JUDUL

**OPTIMASI DEEP NEURAL NETWORK UNTUK PREDIKSI
HARGA SAHAM DENGAN KATEGORI FLUKTUASI MENENGAH**



TESIS

Diajukan sebagai salah satu syarat untuk memperoleh gelar
Magister Ilmu Komputer (M.Kom)

DWI ANDRIYANTO

NIM. 14002432

**Program Studi Ilmu Komputer (S2)
Universitas Nusa Mandiri
Jakarta
2022**

SURAT PERNYATAAN ORISINALITAS DAN BEBAS PLAGIARISME

Yang bertanda tangan di bawah ini :

Nama : Dwi Andriyanto
NIM : 14002432
Program Studi : Ilmu Komputer
Jenjang : Strata Dua (S2)
Konsentrasi : Data Mining

Dengan ini menyatakan bahwa tesis yang telah saya buat dengan judul: “Optimasi *Deep Neural Network* Untuk Prediksi Harga Saham Dengan Fluktuasi Menengah” adalah hasil karya sendiri, dan semua sumber baik yang kutip maupun yang dirujuk telah saya nyatakan dengan benar dan tesis belum pernah diterbitkan atau dipublikasikan dimanapun dan dalam bentuk apapun.

Demikianlah surat pernyataan ini saya buat dengan sebenar-benarnya. Apabila dikemudian hari ternyata saya memberikan keterangan palsu dan atau ada pihak lain yang mengklaim bahwa tesis yang telah saya buat adalah hasil karya milik seseorang atau badan tertentu, saya bersedia diproses baik secara pidana maupun perdata dan kelulusan saya dari Program Studi Ilmu Komputer (S2) Universitas Nusa Mandiri dicabut/dibatalkan.

Jakarta, Januari 2022
Yang menyatakan

Dwi Andriyanto

HALAMAN PERSETUJUAN DAN PENGESAHAN TESIS

Tesis ini diajukan oleh :

Nama : Dwi Andriyanto
NIM : 14002432
Program Studi : Ilmu Komputer
Jenjang : Strata Dua (S2)
Konsentrasi : Data Mining
Judul : Optimasi *Deep Neural Network* Untuk Prediksi Harga Saham Dengan Fluktuasi Menengah

Telah dipertahankan pada periode 2022-1 dihadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperoleh untuk memperoleh Magister Ilmu Komputer (M.Kom) pada Program Studi Ilmu Komputer (S2) Universitas Nusa Mandiri.

Jakarta, Januari 2022

PEMBIMBING TESIS

Pembimbing I : Dr. Yan Riyanto M.Eng

DEWAN PENGUJI

Penguji I :

Penguji II : :

Penguji III /
Pembimbing I : Dr. Yan Riyanto M.Eng

KATA PENGANTAR

Puji syukur penulis panjatkan kehadiran Allah, SWT, yang telah melimpahkan rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan tesis ini sesuai dengan waktu yang diharapkan.

Tesis dengan judul “*Optimasi Deep Neural Network Untuk Prediksi Harga Saham Dengan Fluktuasi Menengah*” dibuat sebagai salah satu untuk mendapatkan gelar Magister Ilmu Komputer (M.Kom) pada Program Studi Ilmu Komputer (S2) Universitas Nusa Mandiri.

Penelitian ini menitikberatkan pada prediksi harga saham dengan tingkat fluktuasi menengah menggunakan metode *deep learning*. Selanjutnya dilakukan optimasi pada beberapa parameter untuk mencari metode terbaik serta dilakukan penilaian menggunakan metrik performa eror. Berbagai sumber referensi penelitian mengacu kepada jurnal ilmiah, buku-buku literatur maupun internet sebagai dasar teori bahasan serta tidak lupa dibuat simulasi penerapan pada saham menengah Bursa Efek Indonesia (BEI).

Dalam kesempatan yang baik ini ijin penulis mengucapkan terimakasih kepada:

1. Bapak Dr. Yan Riyanto M.Eng, selaku pembimbing tesis yang telah menyediakan waktu, pikiran dan tenaga untuk membimbing penulis dalam menyelesaikan tesis ini.
2. Ayah dan Ibu yang selalu berdoa siang malam untuk kemudahan kelancaran dalam penyusunan tesis.
3. Utami Rahmayanti, istriku yang senantiasa memberikan motivasi dan semangat, sehingga tesis ini dapat disusun dan diselesaikan tepat pada waktunya.
4. Segenap Dosen serta civitas Program Studi Ilmu Komputer (S2) Universitas Nusa Mandiri yang telah memberikan dukungan selama masa pembelajaran.
5. Seluruh pihak yang tidak dapat kami sebutkan satu persatu yang telah mendukung terwujudnya penulisan tesis ini.

Semoga dengan adanya tesis ini dapat memberikan tambahan kemanfaatan penelitian di bidang data mining terutama untuk penulis sendiri maupun pembaca sekalian.

Jakarta, Januari 2022
Penulis,

Dwi Andriyanto

**SURAT PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH
UNTUK KEPENTINGAN AKADEMIS**

Yang bertanda tangan di bawah ini, saya :

Nama : Dwi Andriyanto
NIM : 14002432
Program Studi : Ilmu Komputer
Jenjang : Strata Dua (S2)
Konsentrasi : *Data Mining*
Jenis Karya : Tesis

Demi pengembangan ilmu pengetahuan, dengan ini menyetujui untuk memberikan ijin kepada pihak Program Studi Ilmu Komputer (S2) Universitas Nusa Mandiri **Hak Bebas Royalti Non-Eksklusif (*Non-exclusive Royalti-Free Right*)** atas karya ilmiah kami yang berjudul: “*Optimasi Deep Neural Network Untuk Prediksi Harga Saham Dengan Fluktuasi Menengah*” beserta perangkat yang diperlukan (apabila ada).

Dengan **Hak Bebas Royalti Non-Eksklusif** ini pihak Universitas Nusa Mandiri berhak menyimpan, mengalih-media atau bentukkan, mengelolanya dalam pangkalan data (*database*), mendistribusikannya dan menampilkan atau mempublikasikannya di *internet* atau media lain untuk kepentingan akademis tanpa perlu meminta ijin dari kami selama tetap mencantumkan nama kami sebagai penulis/pencipta karya ilmiah tersebut.

Saya bersedia untuk menanggung secara pribadi, tanpa melibatkan pihak Universitas Nusa Mandiri, segala bentuk tuntutan hukum yang timbul atas pelanggaran Hak Cipta dalam karya ilmiah saya ini.

Demikian pernyataan ini saya buat dengan sebenarnya.

Jakarta, Januari 2022
Yang menyatakan

Dwi Andriyanto

ABSTRAK

Nama : Dwi Andriyanto
NIM : 14002432
Program Studi : Ilmu Komputer
Jenjang : Strata Dua (S2)
Konsentrasi : *Data Mining*
Judul : Optimasi Deep Neural Network Untuk Prediksi
Harga Saham Dengan Fluktuasi Menengah

Salah satu perdagangan online diantaranya perdagangan saham di bursa, bahkan untuk meningkatkan jumlah investor pemerintah mengajak masyarakat berinvestasi di pasar modal dengan membeli saham secara rutin dan berkala dalam bentuk saham. Dengan bertambahnya calon investor dalam bursa saham tentu dibutuhkan pengetahuan tentang seluk beluk perdagangan saham agar hasil dari pengembalian sesuai yang dikehendaki. Dengan penelitian ini dapat membantu mempermudah masyarakat untuk melakukan prediksi harga saham yang dikehendaki melalui teknologi *machine learning* meskipun belum memiliki ilmu teknikal tentang saham lebih mendalam. Tiga jenis algoritma RNN,LSTM,GRU digunakan untuk mencari metode terbaik dengan melakukan optimasi parameter sehingga mendapatkan *r-square error* 0,96 melalui jumlah *epoch* 100 dan *learning rate* 0,01

Kata kunci: *saham,time series,rnn,lstm,gru, neural network*

ABSTRACT

Nama : Dwi Andriyanto
NIM : 14002432
Program Studi : Ilmu Komputer
Jenjang : Strata Dua (S2)
Konsentrasi : *Data Mining*
Judul : Deep Neural Network Optimization For Prediction
Stock Prices With Medium Fluctuations

One of the online trades is stock trading on the stock exchange, even to increase the number of investors, the government invites the public to invest in the capital market by buying shares regularly and periodically in the form of shares. With the increase in potential investors in the stock market, knowledge about the ins and outs of stock trading is needed so that the returns are as desired. With this research, it can help make it easier for the public to predict the desired stock price through machine learning technology even though they do not have more in-depth technical knowledge about stocks. Three types of algorithms RNN, LSTM, GRU are used to find the best method by optimizing parameters so as to get an r-square error of 0.95 through the number of epochs of 100 and a learning rate of 0.01.

Keywords: *saham, time series, rnn, lstm, gru, neural network*

DAFTAR ISI

Halaman

HALAMAN SAMPUL	i
HALAMAN JUDUL	ii
SURAT PERNYATAAN ORISINALITAS DAN BEBAS PLAGIARISME.....	iii
HALAMAN PERSETUJUAN DAN PENGESAHAN TESIS.....	iv
KATA PENGANTAR	v
SURAT PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS	vii
ABSTRAK.....	vi
ABSTRACT.....	vii
DAFTAR ISI.....	viii
DAFTAR TABEL.....	x
DAFTAR GAMBAR	xi
DAFTAR RUMUS	xii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang Penulisan	1
1.2 Identifikasi Masalah	2
1.3 Tujuan Penelitian.....	3
1.4 Ruang Lingkup Penelitian	3
1.5 Kontribusi Tesis	3
1.6 Sistematika Penulisan.....	4
BAB 2 LANDASAN/KERANGKA PEMIKIRAN.....	5
2.1 Tinjauan Pustaka	5
2.1.1 Saham	5
2.1.2 Preprocessing Data	7
2.1.3 <i>Reccurent Neural Network</i>	8
2.1.4 Long Short Term Memory (LSTM)	10
2.1.5 Gate Recurrent Unit (GRU).....	11
2.2 Pengaturan Parameter Untuk Meningkatkan Kinerja Model	12
2.3 Metrik Performa Eror	12
2.3.2 <i>R Square</i> atau Koefisien Determinasi	13
2.3.3 <i>Mean Absolute Error</i> (MAE)	13
2.3.4 <i>Mean Absolute Percentage Error</i> (MAPE).....	13
2.3.5 <i>Root Mean Squared Error</i> (RMSE)	13
2.4 Tinjauan Studi	14
2.5 Tinjauan Obyek Penelitian	25
BAB 3 METODOLOGI PENELITIAN	26
3.1 Dataset dan Permasalahannya	26
3.2 Eksperimen Yang Akan Dilakukan	26
3.2.1 Penyesuaian Interval Hari.....	27
3.2.2 Penanganan Data Kosong.....	27
3.2.3 Skala Data.....	27
3.3 Rancangan Model Arsitektur.....	27
3.3.1 Model 1 dengan Algoritma RNN	28
3.3.2 Model 2 dengan Algoritma LSTM	29
3.3.3 Model 3 dengan Algoritma GRU	30
3.4 Metrik Performa Eror	32
3.5 Pengembangan Aplikasi	32
BAB 4 HASIL PENELITIAN DAN PEMBAHASAN	33

4.1	Analisis Statistik Dataset.....	33
4.2	Hasil Eksperimen dan Pengaturan Parameter.....	34
4.2.1	Model 1 dengan Algoritma RNN	34
4.2.1.1	Hasil Model RNN Optimizer Adam.....	34
4.2.1.2	Hasil Model 1 RNN Optimizer Adamax.....	35
4.2.1.3	Hasil Model 1 RNN Optimizer RMSProp.....	36
4.2.2	Model 2 dengan Algoritma LSTM	37
4.2.2.1	Hasil Model 2 LSTM Optimizer Adam	37
4.2.2.2	Hasil Model 2 LSTM Optimizer Adamax.....	38
4.2.2.3	Hasil Model 2 LSTM Optimizer RMSProp	39
4.2.3	Model 3 dengan Algoritma GRU	40
4.2.3.1	Hasil Model 3 GRU Optimizer Adam.....	40
4.2.3.2	Hasil Model 3 GRU Optimizer Adamax.....	41
4.2.3.3	Hasil Model 3 GRU Optimizer RMSProp.....	42
4.3	Evaluasi Metrik Performa Error	42
4.4	Usulan Model Dengan Kinerja Terbaik.....	43
4.5	Impelementasi Aplikasi Prediksi Saham Bursa Efek Indonesia (BEI)...	44
BAB 5	PENUTUP	47
5.1.	Kesimpulan.....	47
5.1.	Saran.....	48
DAFTAR	REFERENSI	49
DAFTAR	RIWAYAT HIDUP.....	52
LEMBAR	BIMBINGAN TESIS	54
LAMPIRAN	KODE.....	55

DAFTAR TABEL

	Halaman
1. Tabel 2.1 Penelitian Terkait Prediksi Saham	22
2. Tabel 3.1 Arsitektur Model 1 dengan Algoritma RNN	28
3. Tabel 3.2 Arsitektur Model 2 dengan Algoritma LSTM	29
4. Tabel 3.3 Arsitektur Model 3 dengan Algoritma GRU	31
5. Tabel 4.1 Deskripsi Statistik	33
6. Tabel 4.2 Hasil Model 1 RNN Optimizer Adam	34
7. Tabel 4.3 Hasil Model 1 RNN Optimizer Adamax	35
8. Tabel 4.4 Hasil Model 1 RNN Optimizer RMSProp	36
9. Tabel 4.5 Hasil Model 2 LSTM Optimizer Adam	37
10. Tabel 4.6 Hasil Model 2 LSTM Optimizer Adamax	38
11. Tabel 4.7 Hasil Model 2 LSTM Optimizer RMSProp	39
12. Tabel 4.8 Hasil Model 3 GRU Optimizer Adam	40
13. Tabel 4.9 Hasil Model 3 GRU Optimizer Adamax	41
14. Tabel 4.10 Hasil Model 3 GRU Optimizer RMSProp	42
15. Tabel 4.11 Kompilasi Metrik Performa Error	43
16. Tabel 4.12 Penerapan Model Untuk Saham Bursa Efek Indonesia	45
17. Tabel 4.13 Hasil Pengujian Model Untuk Saham BEI	46

DAFTAR GAMBAR

	Halaman
1. Gambar 2.1 Arsitektur RNN	8
2. Gambar 2.2 Arsitektur GRU	11
3. Gambar 3.1 Tahapan Penelitian	27
4. Gambar 3.2 Rancangan Model Arsitektur	28
5. Gambar 4.1 Grafik Kinerja Model Terbaik	44

DAFTAR RUMUS

	Halaman
1. Rumus 2.1 Back Propagation Through Time 1.....	9
2. Rumus 2.2 Back Propagation Through Time 2.....	9
3. Rumus 2.3 Back Propagation Through Time 3.....	9
4. Rumus 2.4 Loss Function	9
5. Rumus 2.5 Cross Entropy	9
6. Rumus 2.6 Fungsi Sigmoid	10
7. Rumus 2.7 Input Gate	10
8. Rumus 2.8 Cell State 1	10
9. Rumus 2.9 Cell State 2	10
10. Rumus 2.10 Output Gate	11
11. Rumus 2.11 LSTM	11
12. Rumus 2.12 Gradien Hilang	12
13. Rumus 2.13 Gerbang Reset	12
14. Rumus 2.14 Output Cell	12
15. Rumus 2.15 R Square atau Koefisien Determinasi	13
16. Rumus 2.16 Mean Absolute Error (MAE)	13
17. Rumus 2.17 Mean Absolute Percentage Error (MAPE)	13
18. Rumus 2.18 Root mean Squared Error (RMSE)	13

BAB 1

PENDAHULUAN

1.1 Latar Belakang Penulisan

Hampir seluruh negara telah mengalami pandemi yang dikenal dengan *Covid-19*, tak terkecuali Indonesia. Efek pandemi tidak hanya berpengaruh terhadap aspek kesehatan tetapi juga berdampak terhadap kegiatan ekonomi masyarakat. Perubahan pola transaksi ekonomi yang biasa dilakukan secara langsung melalui kegiatan perdagangan di pasar, kini mulai menyesuaikan melalui perdagangan online mengikuti kebijakan pemerintah terhadap pembatasan kegiatan masyarakat atau yang dikenal dengan istilah PPKM.

Salah satu perdagangan online diantaranya perdagangan saham di bursa, bahkan untuk meningkatkan jumlah investor pemerintah mengajak masyarakat berinvestasi di pasar modal dengan membeli saham secara rutin dan berkala dalam bentuk yuk nabung saham [1]. Dengan bertambahnya calon investor dalam bursa saham tentu dibutuhkan pengetahuan tentang seluk beluk perdagangan saham agar hasil dari pengembalian sesuai yang dikehendaki.

Penelitian yang dilakukan P. Dey dkk[2] untuk kategori saham dengan fluktuasi sedang (perdagangan 5 harian) dalam hal ini menggunakan dataset Oracle kurun waktu 2000-2020 menghasilkan performa metrik *R-Square* 0,90 tidak sebaik yang dihasilkan terhadap perdagangan saham dengan fluktuasi rendah dan tinggi menggunakan dataset untuk kurun waktu yang sama berupa data pergerakan saham *Honda Motor Company* (HMC) dan INTU yaitu diatas rata-rata 0,96. Untuk itu penelitian selanjutnya difokuskan pada dataset Oracle dengan dilakukan beberapa seting parameter berupa *epoch*, *learning rate* maupun *tuning* optimiser agar menghasilkan metrik performa eror yang lebih baik dari penelitian sebelumnya.

Prediksi harga saham melalui rekayasa fitur delapan trigram disertai pembelajaran mesin secara ensemble khususnya prediksi pola stok harian yaitu dengan cara menggabungkan grafik kandil tradisional dengan metode kecerdasan buatan. Metode tersebut dapat memberikan metode prediksi pembelajaran mesin yang sesuai untuk setiap pola berdasarkan hasil yang dilatih dengan menggunakan

data dari tahun 2000 hingga 2017 pasar saham China menghasilkan akurasi prediksi lebih dari 60% untuk beberapa pola tren. Indikator tambahan dapat meningkatkan akurasi seperti momentum, peningkatan jumlah data, standarisasi fitur, dan penghapusan data anomali dapat secara efektif mengatasi gangguan data[3].

Penggunaan model Regresi Logistik memberikan akurasi rata-rata maksimum 68,622% untuk prediksi harga saham Apple. Model pembelajaran dibandingkan dan dianalisis dengan memahami berbagai istilah secara teknik terkait dengan keuangan dan pasar modal pada umumnya di pasar saham (Indeks Pasar Saham, Saham Beredar, Kapitalisasi Pasar, S&P500) sangat membantu dalam preprocessing dataset untuk mencapai hasil terbaik[4].

Arsitektur model untuk prediksi harga saham diusulkan dengan memanfaatkan dua algoritma yaitu Long Short Term Memory (LSTM), dan model BiDirectional Long Short Term Memory (BI-LSTM). Melalui pengaturan hyperparameter yang tepat, penelitian tersebut dapat memperkirakan tren saham di masa depan dengan akurasi tinggi. RMSE untuk model LSTM dan BI-LSTM diukur dengan memvariasikan jumlah epoch, hidden layer, lapisan padat, dan unit berbeda yang digunakan dalam lapisan tersembunyi untuk menemukan model yang lebih baik yang dapat digunakan untuk meramalkan harga saham di masa depan dengan tepat[5].

1.2 Identifikasi Masalah

Dengan latar belakang di atas, peneliti tertarik untuk membahas lebih dalam untuk mencapai metrik performa eror yang lebih baik. Sehingga dengan alasan tersebut dalam melakukan identifikasi masalah akan difokuskan kepada :

- a Bagaimana pengaruh perubahan metrik performa eror apabila dilakukan tuning paramater seperti perubahan jumlah *epoch*, *learning rate*, pemilihan *optimizer* terhadap model algoritma yang digunakan?
- b Bagaimana pengaruh penerapan metode terbaik dalam penelitian ini khususnya saham dengan fluktuasi menengah yang terdaftar pada Bursa Efek Indonesia ?

1.3 Tujuan Penelitian

Penelitian dilakukan dengan tujuan membangun model *Deep Learning* dengan *Hyperparameter Tuning* untuk meningkatkan performa model. Selain itu membangun model dengan metode lain untuk mencari metode yang cocok dengan dataset terkait berdasarkan performa modelnya, dan menghasilkan model yang baik dalam memprediksi harga saham. Bagi pihak terkait penelitian ini dapat membantu masyarakat agar lebih tertarik melakukan investasi melalui perdagangan bursa tanpa harus menguasai ilmu teknikal saham lebih mendalam.

1.4 Ruang Lingkup Penelitian

Untuk mempermudah melakukan batasan maka ruang lingkup yang akan dikemukakan dalam penelitian ini meliputi :

- Dataset dibatasi pada *Oracle Corporation* sebagai data yang berfluktuasi sedang (kisaran harga USD 10 hingga USD 60) yang dapat diperoleh melalui laman <https://github.com/ehfahad/Comparative-Analysis-of-RNNs-in-Stock-Price-Prediction>.
- Metode terbaik dari penelitian ini dilakukan implementasi terhadap saham yang tercantum di Bursa Efek Indonesia dengan menggunakan data saham secara acak memiliki kapitalisasi pasar di atas Rp. 500 miliar.
- Data saham secara acak diambil berdasarkan kategori fraksi harga sesuai Peraturan Nomor II-A tentang Perdagangan Efek Bersifat Ekuitas nomor KEP-00061/BEI/07-2021 tanggal 23 Juli 2021.

1.5 Kontribusi Tesis

Penelitian ini diharapkan dapat membantu mempermudah masyarakat untuk melakukan prediksi harga saham yang dikehendaki dengan bantuan machine learning meskipun belum memiliki ilmu teknikal tentang saham lebih mendalam. Penelitian ini menawarkan kebaruan melalui optimasi *epoch* dan *learning rate* terhadap prediksi harga saham yang memiliki nilai fluktuatif menengah dengan

metrik performa eror *R-Square* 0,96 lebih baik dari penelitian sebelumnya[2] yang hanya mencapai 0,90.

1.6 Sistematika Penulisan

BAB 1: PENDAHULUAN

Berisi latar belakang terkait saham dan penelitian terdahulu yang menjadi dasar penelitian. Dijelaskan pula apa yang menjadi batasan atau ruang lingkup yang menjadi panduan dalam proses penelitian.

BAB 2: LANDASAN/KERANGKA PEMIKIRAN

Penjelasan teori yang digunakan untuk kegiatan penelitian baik itu yang berasal dari pustaka maupun penelitian yang telah dilakukan sebelumnya serta landasan obyek yang diteliti.

BAB 3: METODOLOGI PENELITIAN

Membahas metode yang digunakan dalam penelitian dan penjelasan tahapan yang dilakukan pada kegiatan penelitian. Disamping itu, akan dijelaskan model algoritma neural network yang digunakan untuk kegiatan eksperimen.

BAB 4: HASIL PENELITIAN DAN PEMBAHASAN

Menyajikan dan membahas hasil penelitian dengan melakukan *tuning* parameter *learning rate*, *epoch* serta optimasi parameter lainnya dan pemodelan menggunakan algoritma RNN, LSTM dan GRU. Model algoritma yang dipilih akan dikembangkan dalam bentuk aplikasi dan metrik performa yang paling baik akan dibandingkan dengan hasil yang telah dilakukan oleh peneliti sebelumnya.

BAB 5: PENUTUP

Sebagai bab terakhir yang menguraikan kesimpulan dari bab sebelumnya dan saran untuk penelitian selanjutnya.

BAB 2

LANDASAN/KERANGKA PEMIKIRAN

2.1 Tinjauan Pustaka

2.1.1 Saham

Saham merupakan salah satu instrumen keuangan dalam bentuk surat yang menjadi bukti kepemilikan suatu perusahaan. Dengan adanya saham maka seseorang dinyatakan sebagai pemilik sah suatu perusahaan sehingga memiliki andil terhadap aset yang dimiliki oleh perusahaan. Secara prinsip ekonomi pilihan investasi terhadap saham tentu memiliki maksud terhadap pengembalian yang didapat. Pengembalian berupa keuntungan dari kenaikan harga saham atau yang dikenal dengan istilah *capital gain* maupun ketika perusahaan melakukan pembagian deviden pada akhir periode tertentu. Namun jangan lupa selain keuntungan, ketika memilih investasi saham juga mengandung resiko berupa kerugian, yaitu ketika terjadi penurunan harga saham (*capital loss*) dan ada kalanya ketika perusahaan sudah tidak mampu lagi meneruskan aktivitasnya yaitu ketika terjadi kebangkrutan usaha / likuidasi.

Tempat bertemu penjual dan pembeli untuk melakukan transaksi adalah pasar. Hal ini berlaku juga untuk perdagangan saham maka dibuatlah transaksi secara resmi oleh pemerintah melalui Bursa Efek Indonesia (BEI). Dengan adanya BEI ini maka perusahaan yang membutuhkan dana dalam rangka menunjang likuiditas perusahaan dapat mengambil dana secara sah dengan mencatatkan emiten perusahaan di lantai bursa. Investor tidak ragu akan tingkat pengembalian sepanjang memahami aturan yang telah ditentukan.

Guna menjamin keberlangsungan perdagangan dalam pasar maka Bursa telah menerbitkan Peraturan Nomor II-A tentang Perdagangan Efek Bersifat Ekuitas [6]. Ketentuan mengenai harga efek bersifat ekuitas di pasar reguler dan pasar tunai ditetapkan :

- a. Efek Bersifat Ekuitas dengan Harga *Previous* kurang dari Rp200,- (dua ratus rupiah) ditetapkan fraksi sebesar Rp1,- (satu rupiah) dengan jenjang perubahan harga maksimum yang diperkenankan adalah Rp10,- (sepuluh rupiah);

- b. Efek Bersifat Ekuitas dengan Harga *Previous* berada dalam rentang Rp200,- (dua ratus rupiah) sampai dengan kurang dari Rp500,- (lima ratus rupiah) ditetapkan fraksi sebesar Rp2,- (dua rupiah) dengan jenjang perubahan harga maksimum yang diperkenankan adalah Rp20,- (dua puluh rupiah);
- c. Efek Bersifat Ekuitas dengan Harga *Previous* berada dalam rentang Rp500,- (lima ratus rupiah) sampai dengan kurang dari Rp2.000,- (dua ribu rupiah) ditetapkan fraksi sebesar Rp5,- (lima rupiah) dengan jenjang perubahan harga maksimum yang diperkenankan adalah Rp50,- (lima puluh rupiah);
- d. Efek Bersifat Ekuitas dengan Harga *Previous* berada dalam rentang Rp2.000,- (dua ribu rupiah) sampai dengan kurang dari Rp5.000,- (lima ribu rupiah) ditetapkan fraksi sebesar Rp10,- (sepuluh rupiah) dengan jenjang perubahan harga maksimum yang diperkenankan adalah Rp100,- (seratus rupiah);
- e. Efek Bersifat Ekuitas dengan Harga *Previous* Rp5.000,- (lima ribu rupiah) atau lebih, ditetapkan fraksi sebesar Rp25,- (dua puluh lima rupiah) dengan jenjang perubahan harga maksimum yang diperkenankan adalah Rp250,- (dua ratus lima puluh rupiah).

Setiap investor dapat melakukan pemindahan dananya dari satu perusahaan ke perusahaan lain, atau dari satu industri ke industri lain sesuai dengan perkiraan akan keuntungan yang diharapkan seperti deviden dan atau *capital gain* dan preferensi mereka atau risiko dari saham-saham tersebut secara cepat dan aman baik meliputi perdagangan harian atau yang dilakukan secara berkala. Perdagangan/investasi ini tentunya mengharapkan pengembalian (*return*). pengembalian bisa untung/rugi sesuai tingkat resiko. mitigasi risiko berupa portofolio yaitu untung maksimal dan rugi minimal. Tingkat pengembalian di pasar modal berasal dari capital gain (pengembalian jual/beli transaksi saham) serta deviden yang dibagikan oleh perusahaan dalam periode tertentu.

Frekuensi perdagangan saham tentu akan mempengaruhi jumlah saham beredar. akan menarik investor untuk beli maupun jual. Frekuensi adalah berapa kali terjadinya transaksi jual beli saham yang dicatat dalam bentuk volume. Volume perdagangan menggambarkan kondisi efek dan merupakan gambaran likuiditas suatu efek. Volume adalah keseluruhan nilai transaksi pembelian maupun penjualan

saham oleh investor dan sering dijadikan parameter motivasi untuk melakukan kecenderungan beli/jual dalam rangka mendapatkan *capital gain*.

Harga pasar ditentukan harga saat pembukaan (*Open*) dan harga saat penutupan (*Close*). Dalam satu hari perdagangan juga dicatat harga tertinggi (*High*) dan harga terendah (*Low*) atas saham yang terjadi di hari itu. Harga dikalikan dengan jumlah saham yang diperdagangkan merupakan nilai kapitalisasi pasar. Saham dengan kapitalisasi/market value tinggi merupakan incaran investor untuk jangka panjang menggambarkan fundamental perusahaan sehingga memiliki tingkat resiko rendah. Semakin banyak jumlah saham yang diperdagangkan secara harian menunjukkan tingkat likuiditas saham tersebut dan menjadi daya tarik investor untuk melakukan transaksi perdagangan.

Analisis teknis menggunakan level *support* dan *resistance* untuk mengidentifikasi titik harga pada grafik di mana probabilitas mendukung jeda atau pembalikan tren yang berlaku. Support terjadi di mana tren turun diperkirakan akan berhenti karena konsentrasi permintaan. Resistance terjadi di mana tren naik diperkirakan akan berhenti sementara, karena konsentrasi pasokan. Psikologi pasar memainkan peran utama karena pedagang dan investor mengingat masa lalu dan bereaksi terhadap perubahan kondisi untuk mengantisipasi pergerakan pasar di masa depan. Area support dan resistance dapat diidentifikasi pada grafik menggunakan garis tren dan rata-rata bergerak [7].


2.1.2 Preprocessing Data

Sebelum melangkah ke pembentukan model, terlebih dahulu dilakukan penyiapan proses data atau yang dikenal dengan istilah *preprocessing*. Kegiatan ini sangat penting dan berpengaruh terhadap hasil kinerja model, di antara bentuknya antara lain penanganan data kosong, pen-skala-an data dan sebagainya. Preprocessing dataset saham biasanya dilakukan terhadap data yang kosong dimana dapat diisi dengan nilai rata-rata harga saham sebelumnya. Scikit-learn mempunyai fitur penanganan skala yaitu *StandardScaler* yang digunakan untuk membuat tiap fitur memiliki nilai rata-rata 0 dan variansi 1. *MinMaxScaler* yang berfungsi untuk mengubah data berada di rentang 0 sampai 1.

2.1.3 Recurrent Neural Network

Reccurent Neural Network (RNN) memiliki arsitektur dengan sedikit lapisan dengan aliran koneksi mundur sehingga dianggap rumit. Dengan adanya koneksi mundur ini dapat menangani data yang berurutan seperti data yang memiliki *historical (time series)*, mengolah susunan teks seperti susunan kalimat, sub kata atau huruf, namun dapat juga menangani kumpulan data gambar yang bergerak (video). Itulah mengapa karena dapat menangani data dengan koneksi mundur maka RNN dianggap sebagai kategori *Deep Learning* karena dapat mengatasi masalah *vanishing gradient*[8].

Pada dasarnya susunan kata yang berdiri sendiri tidak akan bermakna apabila dikaitkan dengan kata sebelum dan kata sesudahnya. Pengaitan kata ini akan menjadi makna yang dapat dimengerti menjadi sebuah informasi. Begitu pula dengan susunan gambar/suara yang saling berurutan satu sama lain. Pergerakan gambar/suara suatu urutan frame akan menjadi informasi berupa suara lagu atau tontonan menarik. Hal ini berlaku pada algoritma deep learning ini, ketika proses data dilakukan secara berurutan dari satu neuron ke neuron lainnya maka ditambahkan koneksi *loop* yang menyimpan data sebelumnya sehingga dapat digunakan pada pemrosesan berikutnya.



Sumber : [P Dey, 2021]

Gambar 2.1 Arsitektur RNN

Rangkaian arsitektur RNN di atas menjelaskan suatu input data terkini merupakan kondisi masukan data pada saat ini X_t dan waktu sebelumnya X_{t-1} dan masukan data berikutnya X_{t+1} . Data tersebut dilakukan proses melalui U dengan *hidden state* S_t sebagai memori penyimpanan pada waktu t . *Hidden state* S_t merupakan pemrosesan

dari waktu sebelumnya S_{t-1} melalui W . Sehingga berlaku $S_t = f(U_{X_t} + W_{S_{t-1}})$ dimana fungsi f adalah fungsi aktivasi dapat berupa fungsi tangen hiperbolik (\tanh) atau *rectified liner unit* (ReLU) dengan kondisi awal S_{t-1} bernilai 0 dan O_t adalah hasil keluaran pada state dengan waktu ke- t yang dapat berupa *softmax* atau *sigmoid* biasa.

Variasi arsitektur RNN dapat diuraikan sebagai berikut :

- a Arsitektur RNN *one to many*, untuk mengatasi permasalahan data yang bersifat berurutan. Sebagai contoh pada input masukan berupa gambar dengan keluaran berupa kata-kata atau kalimat.
- b Arsitektur RNN *many to one*, untuk mengatasi permasalahan data yang bersifat berurutan serta keluaran dalam bentuk klasifikasi seperti contoh prediksi harga saham, sentimen analisis positif atau negatif.
- c Arsitektur RNN *many to many*, untuk mengatasi permasalahan data masukan dan keluaran yang bersifat berurutan seperti pada mesin penerjemah bahasa.
- d Arsitektur RNN *many to many*, untuk mengatasi permasalahan data masukan dan keluaran tanpa jeda seperti pada rekaman CCTV.

Sesuai dengan karakteristik RNN yang merupakan lapisan jaringan syaraf meski sederhana tetapi membutuhkan perulangan karena akan digunakan beberapa kali dengan waktu yang berurutan. Sehingga proses pembelajaran pada RNN terikat pada rangkaian waktu oleh karenanya algoritma ini disebut pula sebagai pembelajaran *Back Propagation Through Time* (BPPT).

Keluaran dari hidden layer pada satu langkah waktu ke- t digunakan formula :

$$h_t = f_w(h_{t-1}, x_t) \quad (2-1)$$

$$h_t = \tanh (w_{hh} h_{t-1} + w_{sh} x_t + b_h) \quad (2-2)$$

Keluaran untuk satu langkah waktu ke- t digunakan formula :

$$o_t = f_o(w_{ho} h_t + b_o) \quad (2-3)$$

Untuk *loss function* digunakan formula *cross entropy* :

$$E_t(o_t, \hat{o}_t) = - O_t \log (\hat{O}_t) \quad (2-4)$$

$$E = \sum_t E_t(O_t, \hat{O}_t) = \sum_t - O_t \log (\hat{O}_t) \quad (2-5)$$

dimana E adalah total *loss function* pada satu urutan masukan, $E_t(o_t, o_t)$ merupakan *loss function* untuk satu langkah waktu t dan \hat{O}_t merupakan nilai sebenarnya dari keluaran pada langkah waktu ke- t .

2.1.4 Long Short Term Memory (LSTM)

Dalam pembelajaran *Back Propagation Through Time* (BPPT), semakin panjang masukan suatu urutan akan menyebabkan perhitungan semakin kompleks dalam memproses *gradient* sehingga akan membatasi kemampuan RNN. Sebagai contoh dalam kalimat “mobil merah melaju kencang di jalan tol”. Inti dari kalimat tersebut adalah mobil melaju kencang bukan mobil merah. Dalam hal ini rangkaian data yang harus diproses adalah sepanjang kalimat tersebut. Keterbatasan RNN biasa yang tidak dapat memproses rangkaian panjang dapat diatasi dengan gradien menghilang (*vanishing gradient*). Solusi arsitektur Long Short Term Memory (LSTM) diusulkan pada tahun 1997 oleh Sepp Hochreiter dan Jürgen Schmidhuber menggunakan 4 gerbang untuk mengatasi permasalahan tersebut.

Langkah awal dalam LSTM menentukan informasi yang akan dibuat dari C_{t-1} menggunakan fungsi sigmoid (σ) atau yang disebut dengan gerbang lupa (*forget gate*). Fungsi dari sigmoid yaitu menentukan apakah informasi akan diteruskan dengan nilai 1 atau informasi akan dihentikan karena bernilai 0. Formulasinya adalah sebagai berikut :

$$f_t = \sigma(w_f[S_{t-1}, x_t] + b_f) \quad (2-6)$$

Selanjutnya menentukan informasi yang akan ditambahkan ke C_t yang merupakan penggabungan dari *hidden state* waktu sebelumnya S_{t-1} dan informasi saat ini x_t dengan menggunakan fungsi sigmoid sebagai gerbang masukan (*input gate*) dan fungsi tanh sebagai gerbang lanjutan (*intermediate gate*). Hasil informasi merupakan perkalian akan ditambahkan pada *cell state* pada kondisi terkini C_t . Formula yang digunakan yaitu :

$$i_t = \sigma(w_i[S_{t-1}, x_t] + b_i) \quad (2-7)$$

$$\hat{c}_t = \tanh(w_c[S_{t-1}, x_t] + b_c) \quad (2-8)$$

$$\hat{c}_t = f_t * C_{t-1} + i_t * \hat{c}_t \quad (2-9)$$

Langkah terakhir menentukan keluaran LSTM perlu dihitung terlebih dahulu sigmoid dari gabungan S_{t-1} dan x_t yang merupakan gerbang keluaran (*output gate*).

Gerbang keluaran ini menentukan nilai cell state yang dihasilkan pada S_t . Selanjutnya dihitung nilai fungsi tanh dari C_t dikalikan dengan nilai gerbang keluaran dan hasilnya menjadi keluaran dari LSTM :


$$o_t = \sigma(w_0 [S_{t-1}, x_t] + b_0) \quad (2-10)$$

$$S_t = \tanh * (C_t) \quad (2-11)$$

2.1.5 Gate Recurrent Unit (GRU)

Pengembangan LSTM terhadap beberapa variasi seperti *peephole connection* yakni menggabungkan gerbang masukan dan gerbang lupa, dikenal dengan istilah *Gate Recurrent Unit* (GRU) yang dipopulerkan oleh Cho dan Chung pada tahun 2014. Prinsipnya adalah menyederhanakan proses komputasi namun memiliki kinerja yang setara. Pada GRU gerbang lupa digabung dengan gerbang masukan menjadi satu yaitu gerbang perubahan (*update gate*). GRU juga menggabungkan *cell state* ke dalam *hidden state* [9].

GRU juga mirip dengan RNN melakukan penyempurnaan dalam rangka menghilangkan masalah gradien. Bedanya dalam algoritma GRU menggunakan gerbang pembaruan dan reset gerbang dimana ini menjadi hal yang penting dalam memutuskan informasi untuk diteruskan ke output. Secara lebih spesifik GRU dapat menyimpan informasi tanpa menghapusnya dari waktu ke waktu serta dapat menghapus informasi yang tidak relevan dengan apa yang telah diprediksi dalam data[2].



Sumber : [P. Dey, 2021]
Gambar 2.2 Arsitektur GRU

Gerbang pembaruan membantu model untuk menentukan seberapa banyak informasi masa lalu untuk diteruskan ke masa depan. Hal ini berpengaruh kuat

mengingat model dapat menyimpan informasi dari masa lalu dan membuang risiko masalah gradien hilang. Persamaan yang digunakan yaitu (2-12):

$$z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1} + b^{(z)}) \quad (2-12)$$

Gerbang reset digunakan untuk memutuskan berapa banyak informasi masa lalu yang harus dilupakan dan dihitung dengan persamaan (2-13).

$$r_t = \sigma(W^{(r)}x_t + U^{(r)}h_{t-1} + b^{(r)}) \quad (2-13)$$

Pada akhirnya output sel akan dihitung dengan persamaan (2-14).

$$r_t = z_t \odot h_{t-1} + (1-z_t) \odot \hat{h}_t \quad (2-14)$$

di mana vektor aktivasi kandidat $\hat{h}_t = \tanh(Wx_t + r_t \odot Uh_{t-1} + b^{(h)})$

2.2 Pengaturan Parameter Untuk Meningkatkan Kinerja Model

Dalam membangun model diperlukan berbagai kombinasi *hyperparameter* untuk mendapat kinerja yang terbaik. Pengaturan diperlukan selama pembelajaran karena ditujukan untuk mengontrol proses yang akan dipelajari oleh algoritma sampai ditemukan nilai yang maksimal. Beberapa contoh parameter yang sering digunakan diantaranya *train-test split ratio, learning rate, optimizer (Gradient Descent, ADAMAX, RMSProp, Adam)*, fungsi aktivasi (*Sigmoid, Relu, Tanh*), *loss function, drop out*.

2.3 Metrik Performa Error

Untuk memastikan bahwa model yang dibuat apakah bekerja sesuai dengan harapan diperlukan ukuran yang jelas. Caranya adalah dengan membandingkan nilai sebenarnya (Y) dan nilai prediksi (\hat{Y}) untuk sejumlah (n) data. Semakin kecil nilai eror maka hasilnya semakin bagus. Penelitian ini termasuk dalam kategori regresi sehingga metrik yang digunakan di antaranya [10] :

2.3.2 R Square atau Koefisien Determinasi

R Square atau koefisien determinasi dapat diartikan sebagai proporsi varians dalam variabel dependen yang dapat diprediksi dari variabel independen. Semakin mendekati 1 maka hasilnya adalah yang terbaik[11]. Rumus yang digunakan yaitu

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} \quad (2-15)$$

2.3.3 Mean Absolute Error (MAE)

Nilai absolut dari selisih nilai prediksi dan nilai sebenarnya. Tujuan dari operasi absolut adalah meniadakan eror negatif dan positif. Rumus yang digunakan yaitu :

$$MAE = \sum_{i=1}^n |Y_i - \hat{Y}_i| \quad (2-16)$$

2.3.4 Mean Absolute Percentage Error (MAPE)

Mempunyai interpretasi yang sangat intuitif untuk kesalahan relatif sehingga lebih cocok untuk penanganan eror dengan variasi relatif daripada variasi absolut. Namun memiliki sejumlah kelemahan terhadap data yang benar-benar positif menurut definisi dan bias terhadap prakiraan rendah. Tidak cocok untuk model prediktif di mana kesalahan besar diharapkan[11]. Rumus yang digunakan yaitu :

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{Y_i - \hat{Y}_i}{Y_i} \right| \quad (2-17)$$

2.3.5 Root Mean Squared Error (RMSE)

Nilai kuadrat dari selisih nilai prediksi dan nilai sebenarnya. Tujuan dari operasi kuadrat adalah meniadakan eror negatif dan positif sehingga memiliki kontribusi yang sama. Rumus yang digunakan yaitu :

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n}} \quad (2-18)$$

2.4 Tinjauan Studi

Investor di pasar saham selalu mencari teknik baru dan unik agar mereka berhasil memprediksi pergerakan harga saham dan menghasilkan keuntungan besar. Namun, investor terus mencari teknik yang lebih baik dan baru untuk mengalahkan pasar, bukan yang lama dan tradisional. Oleh karena itu, para peneliti terus bekerja untuk membangun teknik baru untuk memenuhi permintaan investor. Berbagai jenis jaringan saraf berulang (RNN) digunakan dalam analisis deret waktu, terutama dalam prediksi harga saham. Namun, karena tidak semua harga saham mengikuti tren yang sama, satu model tidak dapat digunakan untuk memprediksi pergerakan semua jenis harga saham. Oleh karena itu, dalam penelitian ini dilakukan analisis komparatif terhadap tiga RNN yang umum digunakan—simple RNN, *Long Short Term Memory* (LSTM), dan *Gated Recurrent Unit* (GRU)—dan menganalisis efisiensinya untuk saham-saham yang memiliki trend saham yang berbeda dan rentang harga yang bervariasi dan untuk frekuensi waktu yang berbeda dengan mempertimbangkan kumpulan data tiga perusahaan dari 30 Juni 2000 hingga 21 Juli 2020. Saham mengikuti tren pergerakan harga yang berbeda, dengan kisaran harga \$30, \$50, dan \$290 selama periode ini. Kami juga menganalisis kinerja untuk interval waktu satu hari, tiga hari, dan lima hari. Kami membandingkan kinerja RNN, LSTM, dan GRU dalam hal metrik nilai R², MAE, MAPE, dan RMSE. Hasil penelitian menunjukkan bahwa RNN sederhana mengungguli LSTM dan GRU karena RNN rentan terhadap masalah gradien hilang, sedangkan dua model lainnya tidak. Selain itu, GRU menghasilkan kesalahan yang lebih rendah dibandingkan dengan LSTM. Hal ini juga terbukti dari hasil bahwa ketika interval waktu semakin kecil, model menghasilkan kesalahan yang lebih rendah dan keandalan yang lebih tinggi [2].

Penelitian sebelumnya telah dilakukan untuk mengetahui berapa nilai yang akan dibidik dan berapa banyak saham yang harus dilepas dengan dua metode Regresi dan Klasifikasi. Dalam regresi, sistem memprediksi harga penutupan saham suatu perusahaan, dan dalam klasifikasi, sistem memprediksi apakah harga penutupan saham akan naik atau turun pada hari berikutnya. Model Regresi Logistik memberikan akurasi rata-rata maksimum 68,622% [4].

Jaringan saraf dalam (DNN) menggabungkan keunggulan pembelajaran mendalam (DL) dan jaringan saraf dan dapat digunakan untuk memecahkan masalah nonlinier. Mengingat data-data keuangan secara makro dan mikro seringkali berubah dan tidak tetap maka diperlakukan sebagai seri satu dimensi yang dihasilkan oleh proyeksi sistem acak yang terdiri dari beberapa faktor ke dalam dimensi waktu, dan deret harga direkonstruksi menggunakan rekonstruksi fase-ruang deret waktu (PSR). Model prediksi berbasis DNN dirancang berdasarkan metode PSR dan jangka panjang dan pendek jaringan memori (LSTM) untuk DL dan digunakan untuk memprediksi harga saham. Model prediksi yang diusulkan dan beberapa model prediksi lainnya adalah digunakan untuk memprediksi beberapa indeks saham untuk periode yang berbeda. Model RNN yang menggunakan node memori jangka panjang dan pendek (LSTM) efektif dan dapat diperluas ketika digunakan untuk mengatasi sejumlah masalah yang melibatkan data seri. Model-model ini untuk penggunaan umum dan efektif dalam menangkap informasi yang bergantung pada waktu jangka panjang [12].

Di bidang rekayasa fitur, peneliti telah mencoba untuk mengurangi jumlah fitur menggunakan pemilihan fitur berbasis AutoEncoder untuk meningkatkan stok mengembalikan dan mengurangi kesalahan prediksi. Untuk mengevaluasi metode yang diusulkan, ukuran pengembalian yang lebih dekat dengan dunia nyata perdagangan saham yang digunakan. Faktor fundamental seperti investasi, deal baru, new manajemen dan rilis berita akan mempengaruhi pasar. Perlu untuk menambah kepraktisan algoritma dengan meningkatkan akurasi dan komputasinya efisiensi/kompleksitas [13].

Prediksi kinerja saham adalah salah satu masalah yang paling menantang dalam analisis data deret waktu. Dalam penelitian ini, empat strategi berbeda dikembangkan untuk prediksi kinerja saham dan pemilihan fitur dilakukan untuk mencapai kinerja terbaik dalam klasifikasi saham berkinerja baik. Akhirnya, jaringan saraf dalam yang diusulkan dilatih dan dievaluasi berdasarkan data historis pasar saham Jepang. Hasil eksperimen menunjukkan bahwa klasifikasi saham berbasis peringkat yang diusulkan dengan mempertimbangkan strategi volatilitas

historis memiliki kinerja terbaik dalam empat strategi yang dikembangkan mencapai sekitar 20% tingkat penghasilan per tahun atas dasar semua saham dan memiliki risiko lebih rendah [14].

Penelitian ini mengusulkan sistem perdagangan saham berdasarkan parameter analisis teknis yang dioptimalkan untuk membuat poin jual-beli menggunakan algoritme genetika. Model ini dikembangkan menggunakan platform *big data* Apache Spark. Parameter yang dioptimalkan kemudian diteruskan ke jaringan saraf MLP yang dalam untuk prediksi beli-jual-tahan. Saham Dow 30 dipilih untuk validasi model. Setiap saham Dow dilatih secara terpisah menggunakan harga penutupan harian antara 1996-2016 dan diuji antara 2007-2016. Hasilnya menunjukkan bahwa mengoptimalkan parameter indikator teknis tidak hanya meningkatkan kinerja perdagangan saham tetapi juga menyediakan model yang dapat digunakan sebagai alternatif untuk Beli dan Tahan dan model analisis teknis standar lainnya [15].

Peramalan pasar saham adalah tugas yang rumit dan menantang karena sifat deret waktu harga saham yang sangat bising, nonparametrik, kompleks, dan kacau. Dengan skema rekayasa fitur delapan trigram sederhana dari pola kandil antar hari, kami membangun kerangka kerja pembelajaran mesin ansambel baru untuk prediksi pola stok harian, menggabungkan grafik kandil tradisional dengan metode kecerdasan buatan terbaru. Beberapa teknik pembelajaran mesin, termasuk metode pembelajaran mendalam, diterapkan pada data saham untuk memprediksi arah harga penutupan. Kerangka kerja ini dapat memberikan metode prediksi pembelajaran mesin yang sesuai untuk setiap pola berdasarkan hasil yang dilatih. Strategi investasi dibangun sesuai dengan teknik pembelajaran mesin *ensemble*. Hasil empiris dari tahun 2000 hingga 2017 dari pasar saham China mengkonfirmasi bahwa rekayasa fitur kami memiliki kekuatan prediksi yang efektif, dengan akurasi prediksi lebih dari 60% untuk beberapa pola tren. Berbagai tindakan seperti data besar, standarisasi fitur, dan penghapusan data abnormal dapat secara efektif mengatasi gangguan data. Strategi investasi berdasarkan kerangka peramalan kami unggul dalam kinerja saham individual dan portofolio secara teoritis. Namun, biaya

transaksi memiliki dampak yang signifikan terhadap investasi. Indikator teknis tambahan dapat meningkatkan akurasi perkiraan ke berbagai tingkat. Indikator teknis, terutama indikator momentum, dapat meningkatkan akurasi peramalan dalam banyak kasus [3].

Metode *Brown's Weighted Exponential Moving Average* memiliki kelebihan yaitu tingkat akurasi yang lebih baik yang dirasa mampu untuk membantu masalah prediksi harga saham. Algoritme Levenberg-Marquardt memiliki kelebihan mengoptimasi akurasi sehingga diusulkan digunakan sebagai metode optimasi untuk memprediksi harga saham. Adanya prediksi harga saham dengan bantuan metode B WEMA dengan Optimasi LM dapat meningkatkan akurasi prediksi harga saham dibandingkan B-WEMA tanpa optimasi, sehingga mengurangi risiko trading dan meningkatkan persentase keberhasilan. Hasil menunjukkan selisih antara harga nyata dengan prediksi minimum sebesar 4,03%, error terkecil dari MSE sebesar 719,56, dan MAPE sebesar 1,99% [16].

Regresi vektor dukungan (SVR) adalah teknik pembelajaran mesin terawasi yang telah berhasil digunakan untuk memperkirakan volatilitas keuangan. Karena SVR adalah teknik berbasis kernel, pilihan kernel memiliki dampak besar pada akurasi peramalannya. Hasil empiris menunjukkan bahwa SVR dengan kernel hybrid cenderung mengalahkan model kernel tunggal dalam hal akurasi peramalan. Namun demikian, belum pernah dilakukan penerapan hybrid kernel SVR untuk peramalan volatilitas keuangan pada penelitian sebelumnya. Mengingat bahwa bukti empiris menunjukkan bahwa pasar saham berosilasi antara beberapa keadaan yang mungkin, di mana distribusi pengembalian secara keseluruhan adalah campuran dari normal, kami mencoba untuk menemukan jumlah optimal campuran kernel Gaussian yang meningkatkan satu periode ke depan. peramalan volatilitas SVR berdasarkan GARCH(1,1). Kinerja perkiraan campuran satu, dua, tiga dan empat kernel Gaussian dievaluasi pada pengembalian harian indeks Nikkei dan Ibovespa dan dibandingkan dengan SVR–GARCH dengan kernel wavelet Morlet, standar GARCH, Glosten–Jagannathan–Runkle (GJR) dan model EGARCH nonlinier dengan inovasi normal, *student-t*, *skew-student-t* dan *generalized error*

distribution (GED) dengan menggunakan *mean absolute error* (MAE), *root mean squared error* (RMSE) dan *robust* Diebold–Mariano test. Hasil prakiraan *out-of-sample* menunjukkan bahwa SVR-GARCH dengan campuran kernel Gaussian dapat meningkatkan prakiraan volatilitas dan menangkap perilaku pergantian model [17].

Pasar saham adalah poros utama dalam setiap ekonomi yang tumbuh dan berkembang, dan setiap investasi di pasar ditujukan untuk memaksimalkan keuntungan dan meminimalkan risiko terkait. Akibatnya, banyak penelitian telah dilakukan pada prediksi pasar saham menggunakan analisis teknis atau fundamental melalui berbagai teknik dan algoritma *soft-computing*. Studi ini berusaha untuk melakukan tinjauan sistematis dan kritis terhadap sekitar seratus dua puluh dua (122) karya penelitian terkait yang dilaporkan dalam jurnal akademik selama 11 tahun (2007–2018) di bidang prediksi pasar saham menggunakan pembelajaran mesin. Berbagai teknik yang diidentifikasi dari laporan-laporan ini dikelompokkan ke dalam tiga kategori, yaitu analisis teknis, fundamental, dan gabungan. Pengelompokan dilakukan berdasarkan kriteria berikut: sifat kumpulan data dan jumlah sumber data yang digunakan, kerangka waktu data, algoritma pembelajaran mesin yang digunakan, tugas pembelajaran mesin, metrik akurasi dan kesalahan yang digunakan, dan paket perangkat lunak yang digunakan untuk pemodelan. Hasilnya menunjukkan bahwa 66% dokumen yang ditinjau didasarkan pada analisis teknis; sedangkan 23% dan 11% masing-masing didasarkan pada analisis fundamental dan analisis gabungan. Mengenai jumlah sumber data, 89,34% dokumen yang direview menggunakan sumber tunggal; sedangkan 8,2% dan 2,46% masing-masing menggunakan dua dan tiga sumber. Dukungan mesin vektor dan jaringan saraf tiruan ditemukan sebagai algoritma pembelajaran mesin yang paling banyak digunakan untuk prediksi pasar saham [18].

Dalam makalah ini, dua model hibrida digunakan untuk penentuan waktu pasar saham berdasarkan analisis teknis Candlestick Jepang oleh Support Vector Machine (SVM) dan Algoritma Heuristik Persaingan dan Genetika Imperialis. Pada model pertama, SVM dan Imperialist Competition Algorithm (ICA) dikembangkan

untuk *stock market timing* dimana ICA digunakan untuk mengoptimalkan parameter SVM. Pada model kedua, SVM digunakan dengan *Genetic Algorithm* (GA) dimana GA digunakan untuk seleksi fitur selain optimasi parameter SVM. Di sini dua pendekatan, berbasis Raw dan berbasis Sinyal dirancang berdasarkan literatur untuk menghasilkan data input model. Sebagai perbandingan, *Hit Rate* dianggap sebagai persentase prediksi yang benar untuk periode 1–6 hari. Hasilnya menunjukkan bahwa kinerja SVM-ICA lebih baik daripada SVM-GA dan yang paling penting adalah jaringan saraf statis *feed-forward* dari literatur sebagai standar [19].

Menerapkan strategi perdagangan *candlestick* ke data komponen DJIA, peneliti menemukan bahwa terlepas dari definisi tren mana yang digunakan, delapan pola pembalikan tiga hari dengan strategi holding Caginalp–Laurent menguntungkan ketika menetapkan biaya transaksi pada 0,5% dan setelah memperhitungkan untuk bias pengintaian data, sedangkan pola dengan strategi holding Marshall–Young–Rose tidak menguntungkan. Untuk analisis sensitivitas, juga ditemukan bahwa hasil tidak berubah secara kualitatif pada biaya transaksi yang lebih rendah sebesar 0,1%, atau ketika dilakukan analisis subsampel berdasarkan tiga periode yang sama dan tiga kondisi pasar yang berbeda. Saat mempertimbangkan pasar yang lebih bergejolak, bukti yang mendukung strategi perdagangan kandil diperkuat [20].

Makalah ini mempelajari kekuatan prediksi dari 4 pasangan populer pola kandil Jepang naik dan turun dua hari di pasar saham Cina. Berdasarkan studi Morris, kami memberikan rincian kuantitatif definisi long candlestick, yang penting dalam pengenalan pola candlestick dua hari tetapi diabaikan oleh beberapa penelitian sebelumnya, dan selanjutnya kami memberikan definisi kuantitatif dari empat pasang candlestick dua hari ini. pola. Untuk menguji kekuatan prediksi pola kandil pada pergerakan harga jangka pendek, kami mengusulkan definisi pengembalian rata-rata harian untuk mengurangi dampak korelasi antara pengembalian waktu tumpang tindih saham dalam uji statistik. Untuk menunjukkan kekokohan hasil kami, dua metode definisi tren digunakan untuk kumpulan sampel

nilai pasar menengah dan nilai pasar besar. Kami menggunakan uji Step-SPA untuk mengoreksi bias pengintaian data. Hasil statistik menunjukkan bahwa daya prediksi berbeda dari satu pola ke pola lainnya, tiga dari delapan pola memberikan prediksi jangka pendek dan relatif jangka panjang, satu pasangan lainnya hanya memberikan daya peramalan yang signifikan dalam periode jangka pendek, sedangkan sisanya tiga pola. menyajikan hasil yang kontradiktif untuk kelompok nilai pasar yang berbeda. Untuk keempat pasangan tersebut, daya prediksi turun seiring dengan bertambahnya waktu prediksi, dan daya prediksi lebih kuat untuk saham dengan nilai pasar menengah daripada saham dengan nilai pasar besar [21].

Sementara investor di barat umumnya skeptis tentang keandalan analisis teknis candlestick, teknik ini umumnya digunakan di beberapa pasar ekuitas Asia dalam investasi spekulatif jangka pendek. Makalah ini mengkaji efektivitas lima pola pembalikan *candlestick* yang berbeda dalam memprediksi pergerakan saham jangka pendek. Menggunakan data dua bursa China dari 1999 hingga 2008, analisis statistik kami menunjukkan bahwa *bearish* harami, dan sinyal silang berkinerja baik dalam memprediksi pembalikan kepala untuk saham dengan likuiditas rendah, sementara pola *bullish* harami, *engulfing*, dan *piercing* menguntungkan bila diterapkan pada harga yang sangat tinggi. likuid, saham perusahaan kecil [22].

Deep Learning memberikan wawasan yang bermanfaat dengan menganalisis informasi khususnya di bidang keuangan dengan teknologi komputasi canggih. Meskipun, jaringan RNN-LSTM dengan keunggulan pembelajaran sekuensial telah mencapai sukses besar di masa lalu untuk prediksi deret waktu. Sebaliknya, mengembangkan dan memilih jaringan RNN-LSTM yang dioptimalkan secara komputasional terbaik untuk peramalan pasar saham intra-hari adalah tugas yang sangat menantang sebagai peneliti. Karena menganalisis data yang paling fluktuatif, diperlukan untuk mengatasi dua faktor besar seperti jeda waktu dan sejumlah besar hyperparameter arsitektur yang mempengaruhi pembelajaran model. Selanjutnya, selain desain jaringan ini, beberapa penelitian sebelumnya menggunakan heuristik berbasis trial and error untuk memperkirakan faktor-faktor ini yang mungkin tidak menjamin jaringan yang paling optimal.

Makalah ini mendefinisikan solusi untuk memecahkan masalah menantang yang disebutkan di atas menggunakan mekanisme hybrid dari jaringan RNN-LSTM yang terintegrasi dengan teknik optimasi metaheuristik. Untuk ini, pendekatan dua-hibrida yaitu RNN-LSTM dengan algoritma penyerbukan bunga dan RNN-LSTM dengan optimasi gerombolan partikel telah diperkenalkan untuk mengembangkan model pembelajaran mendalam yang optimal untuk meningkatkan prediksi pasar saham intra-hari. Model ini menyarankan metode sistematis yang membantu kami menghasilkan jaringan yang dioptimalkan secara otomatis. Karena jaringan yang diperoleh dengan nilai parametrik hiper yang disetel mengarah ke proses pembelajaran yang lebih tepat dengan tingkat kesalahan yang diminimalkan dan peningkatan akurasi. Selain itu, hasil komparatif yang dievaluasi lebih dari enam kumpulan data bursa yang berbeda mencerminkan kemanjuran jaringan RNN-LSTM yang dioptimalkan dengan mencapai akurasi peramalan maksimum sekitar kenaikan 4-6% menggunakan pendekatan metaheuristik [23].

Prediksi pasar saham adalah upaya untuk menentukan nilai masa depan dari suatu saham yang diperdagangkan di bursa efek. Investor pasar saham mencoba untuk memprediksi harga saham di masa depan untuk membuat keputusan perdagangan sehingga keuntungan yang optimal dapat diperoleh. Model pembelajaran mendalam ditemukan paling berhasil dalam memprediksi harga saham. Makalah ini telah melakukan analisis baru dari parameter periode lihat-belakang yang digunakan dengan jaringan saraf berulang dan juga membandingkan kinerja prediksi harga saham dari tiga model pembelajaran mendalam: Vanilla RNN, LSTM, dan GRU untuk memprediksi harga saham dari dua model paling populer dan terkuat. bank komersial yang terdaftar di Bursa Efek Nepal (NEPSE). Dari percobaan yang dilakukan, ditemukan bahwa GRU paling berhasil dalam prediksi harga saham. Selain itu, pekerjaan penelitian telah menyarankan nilai-nilai yang sesuai dari periode look-back yang dapat digunakan dengan LSTM dan GRU untuk kinerja prediksi harga saham yang lebih baik [24].

Dari beberapa penelitian terkait dengan penggunaan deep learning untuk melakukan prediksi saham dapat diuraikan dalam tabel berikut :

Tabel 2.1. Penelitian Terkait Prediksi Saham

No	Judul	Penulis	Metode	Performa
1	Comparative Analysis of Recurrent Neural Networks in Stock Price Prediction for Different Frequency Domains[6]	P. Dey <i>et al</i> (2021)	RNN, LSTM, dan GRU. Dataset Oracle,HMC, INTU Paper acuan utama untuk dataset yang digunakan.	R^2 sebesar rata-rata 0.96. Dataset Saham Oracle interval 5 hari R^2 sebesar 0,90
2	Prediction of Stock Prices using Machine Learning (Regression, Classification) Algorithms[9]	S. Ravikumar and P. Saraf (2020)	Model regresi logistik	Akurasi rata-rata maksimum 68,62%
3	Stock price prediction based on deep neural networks[10]	P. Yu and X. Yan (2020)	ARIMA,SVR, MLP, LSTM	CORR Arima 0.96, SVR 0.95,MLP 0.96, LSTM 0.94
4	Prediction of Stock Performance Using Deep Neural Networks[12]	Y. Gu, T. Shibukawa, Y. Kondo, S. Nagao, and S. Kamijo (2020)	SVM	Sekitar 5,2% tingkat penghasilan per 12 minggu lebih dari dasar semua saham dicapai dalam pengulangan

				tes.
5	A Deep Neural-Network Based Stock Trading System Based on Evolutionary Optimized Technical Analysis Parameters[13]	O. B. Sezer, M. Ozbayoglu, and E. Dogdu (2017)	Algoritma Genetika, MLP	Parameter indikator teknis menyediakan model alternatif untuk Beli dan tahan.
6	Stock Trend Prediction Using Candlestick Charting and Ensemble Machine Learning Techniques With a Novelty Feature Engineering Scheme [15]	H. Lin, C. Chen, G. Huang, and A. Jafari (2021)	RF, GBDT, LR, KNN, SVM, LSTM	RF dan GBDT memiliki kemampuan prediksi yang baik untuk jangka pendek. KNN dan SVM hanya cocok dalam beberapa pola.
7	Prediksi Harga Saham Menggunakan Metode Brown's Weighted Exponential Moving Average dengan Optimasi Levenberg-Marquardt[16]	Dini Indriyani Putri, Agung Budi Prasetyo, and Adian Fatchur Rochim(2021)	Algoritma Levenberg-Marquardt	MSE sebesar 719,56, dan MAPE sebesar 1,99%

8	Volatility forecasting via SVR–GARCH with mixture of Gaussian kernels[17]	P. C. S. Bezerra and P. H. M. Albuquerque(2017)	SVR-GARCH	Untuk seri Nikkei 225 dan Ibovespa, terbukti bahwa semua model SVR–GARCH secara signifikan mengungguli setiap model GARCH
10	New efficient hybrid candlestick technical analysis model for stock market timing on the basis of the Support Vector Machine and Heuristic Algorithms of Imperialist Competition and Genetic[19]	E. Ahmadi, M. Jasemi, L. Monplaisir, M. A. Nabavi, A. Mahmoodi, and P. Amini Jam(2018)	SVM-ICA	Kinerja SVM-ICA lebih baik daripada SVM-GA
11	Enhanced Prediction of Intra-day Stock Market Using Metaheuristic Optimization on	K. Kumar and M. T. U. Haider (2016)	RNN–LSTM	error rate = 0.14 which is 10% less, precision = 0.87, recall =

	RNN–LSTM Network [23]			0.86 and F1-score = 0.86
12	Analysis of look back period for stock price prediction with RNN variants[24]	A. S. Saud and S. Shakya(2020)	GRU,LSTM	GRU NIB 4.74, and GRU NABIL is and 4.71 LSTM NIB 5.58 and LSTM NABIL 5.06

2.5 Tinjauan Obyek Penelitian

Penelitian ini menggunakan dataset sekunder atau data publik yang diambil dari laman <https://github.com/ehfahad/Comparative-Analysis-of-RNNs-in-Stock-Price-Prediction> berupa data saham Oracle. Berisi kumpulan data selama 20 tahun (dari 30 Juni 2000 hingga 21 Juli 2020) memiliki 6 *features* dan 5.044 *instance* dengan ukuran file 275.8 Kb. Enam *Features* terdiri dari 5 *features* dengan tipe Float yaitu Open (Float), High (Float), Low (Float), Close (Float), Adj Close (Float) dan 1 tipe Integer yaitu Volume(Int). Selanjutnya data disimpan dalam bentuk pickle untuk memudahkan pengolahan.

BAB 3

METODOLOGI PENELITIAN

3.1 Dataset dan Permasalahannya


Penelitian yang dilakukan Polash Dey dan kawan-kawan di tahun 2021 dengan judul “*Comparative Analysis of Recurrent Neural Networks in Stock Price Prediction for Different Frequency Domains*”[2] membahas analisis komparatif terhadap tiga RNN yang umum digunakan yaitu *simple RNN*, *Long Short Term Memory* (LSTM), dan *Gated Recurrent Unit* (GRU) dan menganalisis efisiensinya untuk saham yang memiliki tren saham yang berbeda dan rentang harga yang berbeda dan untuk frekuensi waktu yang berbeda. Dengan menggunakan kumpulan data tiga perusahaan dari 30 Juni 2000 hingga 21 Juli 2020 serta fluktuasi harga saham dengan kisaran harga \$30, \$50, dan \$290 pada periode tersebut. *Honda Motor Company* (HMC) sebagai data yang sedikit berfluktuasi yang harga sahamnya berada di antara USD 15 hingga USD 45, *Oracle Corporation* (ORCL) sebagai data yang berfluktuasi sedang kisaran harga USD 10 hingga USD 60, dan *Intuit Incorporation* (INTU) sebagai data yang sangat berfluktuasi tinggi yang memiliki harga terendah USD 20 dan harga tertinggi USD 310. Rata-rata metrik performa eror berupa R-Square di atas 96% untuk fluktuasi harga saham dengan interval 1 dan 3 hari. Sedangkan untuk interval 5 hari khususnya saham Oracle masih berkisar 90%. Terdapat celah kebaruan menurut peneliti yang masih dapat ditingkatkan. Untuk itu kami tertarik meneliti lebih lanjut dengan menawarkan beberapa metoda agar metrik performa eror yang diharapkan dapat semakin meningkat.

3.2 Eksperimen Yang Akan Dilakukan

Perangkat dalam mengolah data menggunakan *Google Colab Pro* yang dilengkapi akselerator *Graphics Processing Unit* (GPU) dengan memori 8Gb.

Sebagai langkah awal eksperimen berikut kami sampaikan tahapan penelitian yang dimulai dari dataset sampai dengan model performa evaluasi untuk menjadikan dasar pengambilan keputusan atas kinerja model yang terbaik.

Gambar 3.1 Tahapan Penelitian



3.2.1 Penyesuaian Interval Hari

Penelitian ini difokuskan pada perdagangan saham dengan interval 5 hari. Karenanya diperlukan kegiatan awal berupa penyesuaian interval perdagangan yang semula 1 hari menjadi 5 hari. Langkah yang dilakukan dimulai dengan menentukan *features* (tanggal) hari pertama dari jangka waktu 5 hari. Nilai (*open*) diisi dengan harga pembukaan hari pertama dari jangka waktu 5 hari. Nilai (*high*) diisi dengan harga tertinggi dalam jangka waktu 5 hari. Nilai (*low*) diisi dengan harga terendah dalam jangka waktu 5 hari. Nilai (*close*) diisi dengan harga penutupan hari terakhir dari jangka waktu 5 hari. Sedangkan untuk (*volume*) yang diperdagangkan diisi dengan total volume perdagangan dalam jangka waktu 5 hari.

3.2.2 Penanganan Data Kosong

Salah satu kendala dalam penelitian data dengan kategori deret waktu adalah adanya data dengan nilai kosong. Apabila terdapat data dengan nilai kosong akan dapat mengganggu pola pergerakan harga, sehingga apabila tidak ditangani dengan baik akan memiliki pengaruh terhadap prediksi harga saham. Secara umum penanganan data kosong dapat diisi dengan nilai tertentu seperti menggunakan harga saham sebelumnya. Metode ini akan digunakan dalam penelitian untuk menyelesaikan masalah data kosong.

3.2.3 Skala Data


Scikit-learn mempunyai fitur penanganan skala yaitu `StandardScaler` yang digunakan untuk membuat tiap fitur memiliki nilai rata-rata 0 dan variansi 1. `MinMaxScaler` yang berfungsi untuk mengubah data berada di rentang 0 sampai 1.

3.3 Rancangan Model Arsitektur

Model yang akan dikembangkan untuk prediksi harga saham Oracle melalui perdagangan interval 5 hari menggunakan model neural network dengan input layer 4, 1 hidden layer berisi 32 neuron, output layer 1 dan algoritma yang digunakan yaitu Simple RNN, LSTM, dan GRU. Rencana menggunakan 81 model dilatih

dengan data training pada 90% dari total data dan diuji dengan data testing sejumlah 10% data.

Gambar 3.2 Rancangan Model Arsitektur



3.3.1 Model 1 dengan Algoritma RNN

Dengan menggunakan jaringan saraf yang sesuai Simpel RNN sebagai lapisan tersembunyi pertama. Adam, Adamax, RMSProp digunakan sebagai pengoptimal model, dan MSE digunakan sebagai fungsi kerugian. Epoch yang digunakan yaitu 100,200,300 dan Learning rate 0.1, 0.01, 0.001. Penelitian ini mengusulkan bahwa kombinasi seperti ditunjukkan pada Tabel berikut.

Tabel 3.1 Arsitektur Model 1 dengan Algoritma RNN

No	Model	Optimizer	Epoch	Learning Rate
1	RNN	Adam	100	0.1
2	RNN	Adam	100	0.01
3	RNN	Adam	100	0.001
4	RNN	Adam	200	0.1
5	RNN	Adam	200	0.01
6	RNN	Adam	200	0.001
7	RNN	Adam	300	0.1
8	RNN	Adam	300	0.01
9	RNN	Adam	300	0.001

10	RNN	Adamax	100	0.1
11	RNN	Adamax	100	0.01
12	RNN	Adamax	100	0.001
13	RNN	Adamax	200	0.1
14	RNN	Adamax	200	0.01
15	RNN	Adamax	200	0.001
16	RNN	Adamax	300	0.1
17	RNN	Adamax	300	0.01
18	RNN	Adamax	300	0.001
19	RNN	RMSProp	100	0.1
20	RNN	RMSProp	100	0.01
21	RNN	RMSProp	100	0.001
22	RNN	RMSProp	200	0.1
23	RNN	RMSProp	200	0.01
24	RNN	RMSProp	200	0.001
25	RNN	RMSProp	300	0.1
26	RNN	RMSProp	300	0.01
27	RNN	RMSProp	300	0.001

3.3.2 Model 2 dengan Algoritma LSTM

Dengan menggunakan jaringan saraf yang sesuai Simpel LSTM sebagai lapisan tersembunyi pertama. Adam, ADAMAX, RMSProp digunakan sebagai pengoptimal model, dan MSE digunakan sebagai fungsi kerugian. Epoch yang digunakan yaitu 100,200,300 dan Learning rate 0.1, 0.01, 0.001. Penelitian ini mengusulkan bahwa kombinasi seperti ditunjukkan pada Tabel berikut.

Tabel 3.2 Arsitektur Model 2 dengan Algoritma LSTM

No	Model	Optimizer	Epoch	Learning Rate
1	LSTM	Adam	100	0.1
2	LSTM	Adam	100	0.01
3	LSTM	Adam	100	0.001

4	LSTM	Adam	200	0.1
5	LSTM	Adam	200	0.01
6	LSTM	Adam	200	0.001
7	LSTM	Adam	300	0.1
8	LSTM	Adam	300	0.01
9	LSTM	Adam	300	0.001
10	LSTM	Adamax	100	0.1
11	LSTM	Adamax	100	0.01
12	LSTM	Adamax	100	0.001
13	LSTM	Adamax	200	0.1
14	LSTM	Adamax	200	0.01
15	LSTM	Adamax	200	0.001
16	LSTM	Adamax	300	0.1
17	LSTM	Adamax	300	0.01
18	LSTM	Adamax	300	0.001
19	LSTM	RMSProp	100	0.1
20	LSTM	RMSProp	100	0.01
21	LSTM	RMSProp	100	0.001
22	LSTM	RMSProp	200	0.1
23	LSTM	RMSProp	200	0.01
24	LSTM	RMSProp	200	0.001
25	LSTM	RMSProp	300	0.1
26	LSTM	RMSProp	300	0.01
27	LSTM	RMSProp	300	0.001

3.3.3 Model 3 dengan Algoritma GRU

Dengan menggunakan jaringan saraf yang sesuai Simpel GRU sebagai lapisan tersembunyi pertama. Adam, ADAMAX, RMSProp digunakan sebagai pengoptimal model, dan MSE digunakan sebagai fungsi kerugian. Epoch yang digunakan yaitu 100,200,300 dan Learning rate 0.1, 0.01, 0.001. Penelitian ini mengusulkan bahwa kombinasi seperti ditunjukkan pada Tabel berikut.

Tabel 3.3 Arsitektur Model 3 dengan Algoritma GRU

No	Model	Optimizer	Epoch	Learning Rate
1	GRU	Adam	100	0.1
2	GRU	Adam	100	0.01
3	GRU	Adam	100	0.001
4	GRU	Adam	200	0.1
5	GRU	Adam	200	0.01
6	GRU	Adam	200	0.001
7	GRU	Adam	300	0.1
8	GRU	Adam	300	0.01
9	GRU	Adam	300	0.001
10	GRU	Adamax	100	0.1
11	GRU	Adamax	100	0.01
12	GRU	Adamax	100	0.001
13	GRU	Adamax	200	0.1
14	GRU	Adamax	200	0.01
15	GRU	Adamax	200	0.001
16	GRU	Adamax	300	0.1
17	GRU	Adamax	300	0.01
18	GRU	Adamax	300	0.001
19	GRU	Adamax	100	0.1
20	GRU	Adamax	100	0.01
21	GRU	Adamax	100	0.001
22	GRU	RMSProp	200	0.1
23	GRU	RMSProp	200	0.01
24	GRU	RMSProp	200	0.001
25	GRU	RMSProp	300	0.1
26	GRU	RMSProp	300	0.01
27	GRU	RMSProp	300	0.001

3.4 Metrik Performa Error

Berbagai eksperimen dilakukan selama proses training dimana selanjutnya akan dilakukan evaluasi atas setiap model. Evaluasi model akan menggunakan data testing menggunakan *scikit-learn libraries*. Metrik performa yang digunakan untuk mengevaluasi model yaitu *R-Square* atau Koefisien determinasi, *Mean Absolute Error* (MAE), *Mean Absolute Percentage Error* (MAPE), *Root Mean Squared Error* (RMSE). Untuk memastikan model yang dipilih tidak *over-fitting*, dalam menjalankan eksperimen juga dilengkapi dengan *plotting* training dan history *loss* beserta *mae* dan *mse*.

3.5 Pengembangan Aplikasi

Melalui rancangan model dan metrik performa eror yang memiliki kesalahan terkecil dan waktu untuk melakukan komputasi yang tercepat akan dipilih untuk dijadikan model. Model tersebut kemudian diterapkan pada prediksi harga saham saham di Bursa Efek Indonesia dengan kriteria tertentu.

BAB 4

HASIL PENELITIAN DAN PEMBAHASAN

4.1 Analisis Statistik Dataset

Tabel 4.1 Deskripsi Statistik

	Open	High	Low	Close	Adj Close	Volume
count	1,466	1,466	1,466	1,466	1,466	1,466
mean	29	29	28	29	26	30,361,360
std	14	14	14	14	14	17,139,650
min	8	9	7	8	7	5,690,833
0.25	16	16	15	15	13	16,127,140
0.50	28	29	27	28	24	28,065,560
0.75	40	41	40	40	37	39,884,180
max	60	61	59	60	59	126,909,300

Data yang disajikan pada Tabel dapat dianalisis bahwa dataset memiliki 1466 instance. Harga buka terendah adalah \$8 dan harga buka tertinggi \$60 dengan standar deviasi \$14. Kuartil pertama harga buka yaitu \$16, kuartil kedua \$28, dan kuartil ketiga \$40. Rata-rata harga buka \$29. Harga tinggi minimal adalah \$9 dan harga tinggi maksimal \$61 dengan standar deviasi \$14. Kuartil pertama harga tinggi yaitu \$16, kuartil kedua \$29, dan kuartil ketiga \$41. Rata-rata harga tinggi \$29. Harga rendah minimal adalah \$7 dan harga rendah maksimal \$59 dengan standar deviasi \$14. Kuartil pertama harga rendah yaitu \$15, kuartil kedua \$27, dan kuartil ketiga \$40. Rata-rata harga rendah \$28. Harga penutupan minimal adalah \$8 dan harga penutupan maksimal \$60 dengan standar deviasi \$14. Kuartil pertama harga penutupan yaitu \$15, kuartil kedua \$28, dan kuartil ketiga \$40. Rata-rata harga penutupan \$29. Volume minimal adalah 5,690,833 dan volume maksimal 126,909,300 dengan standar deviasi 17,139,650. Kuartil pertama volume yaitu 16,127,140, kuartil kedua 28,065,560, dan kuartil ketiga 39,884,180. Rata-rata volume 30,361,360.

4.2 Hasil Eksperimen dan Pengaturan Parameter

Untuk memudahkan penilaian kinerja model maka eksperimen terhadap data saham Oracle dengan cara mengelompokkan dalam algoritma RNN, LSTM, dan GRU. Sesuai rencana pengembangan model dengan menambahkan pengaturan parameter tuning berupa *optimizer* Adam, Adamax dan RMSProp.

4.2.1 Model 1 dengan Algoritma RNN

4.2.1.1 Hasil Model RNN Optimizer Adam

Hasil eksperimen dengan algoritma RNN dan *optimizer* Adam serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.2 Hasil Model 1 RNN Optimizer Adam

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	RNN ADAM	100	0.1	0.96	0.48	0.01	0.67	42
2		100	0.01	0.96	0.53	0.01	0.70	26
3		100	0.001	0.92	0.76	0.01	0.98	26
4		200	0.1	0.96	0.52	0.01	0.69	51
5		200	0.01	0.96	0.46	0.01	0.68	52
6		200	0.001	0.94	0.67	0.01	0.85	51
7		300	0.1	0.97	0.44	0.01	0.62	83
8		300	0.01	0.96	0.44	0.01	0.65	77
9		300	0.001	0.96	0.46	0.01	0.65	83

Pada tabel di atas memuat hasil pengukuran eror dengan menggunakan algoritma RNN yang diberikan optimasi Adam. Fokus penelitian akan diarahkan kepada performa eror menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 26 detik epoch 100, learning rate 0.01, MAE 0.53, MAPE 0.01, RMSE 0.70 dan R-Square dengan nilai 0.96. Perhitungan kinerja

dengan R-Square tertinggi yaitu dengan nilai 0.97, epoch 300, learning rate 0.1, MAE 0.44, MAPE 0.01, RMSE 0.62 dan waktu 83 detik.

4.2.1.2 Hasil Model 1 RNN Optimizer Adamax

Hasil eksperimen dengan algoritma RNN dan *optimizer* Adamax serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.3 Hasil Model 1 RNN Optimizer Adamax

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	RNN ADAMAX	100	0.1	0.94	0.68	0.01	0.85	37
2		100	0.01	0.96	0.54	0.01	0.71	36
3		100	0.001	0.84	1.09	0.02	1.36	42
4		200	0.1	0.95	0.55	0.01	0.75	73
5		200	0.01	0.97	0.45	0.01	0.63	73
6		200	0.001	0.92	0.71	0.01	0.98	74
7		300	0.1	0.96	0.49	0.01	0.70	78
8		300	0.01	0.96	0.47	0.01	0.68	78
9		300	0.001	0.95	0.58	0.01	0.77	77

Pada tabel di atas memuat hasil pengukuran eror dengan menggunakan algoritma RNN yang diberikan optimasi Adamax. Fokus penelitian akan diarahkan kepada performa eror menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 36 detik epoch 100, learning rate 0.01, MAE 0.54, MAPE 0.01, RMSE 0.71 dan R-Square dengan nilai 0.96. Perhitungan kinerja dengan R-Square tertinggi yaitu dengan nilai 0.97, epoch 200, learning rate 0.01, MAE 0.45, MAPE 0.01, RMSE 0.63 dan waktu 73 detik.

4.2.1.3 Hasil Model 1 RNN Optimizer RMSProp

Hasil eksperimen dengan algoritma RNN dan *optimizer* RMSProp serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.4 Hasil Model 1 RNN Optimizer RMSProp

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	RNN RMSPROP	100	0.1	0.95	0.55	0.01	0.74	28
2		100	0.01	0.95	0.57	0.01	0.75	28
3		100	0.001	0.94	0.63	0.01	0.84	28
4		200	0.1	0.95	0.52	0.01	0.73	55
5		200	0.01	0.92	0.79	0.01	0.96	56
6		200	0.001	0.96	0.46	0.01	0.67	55
7		300	0.1	0.96	0.49	0.01	0.71	82
8		300	0.01	0.96	0.47	0.01	0.66	82
9		300	0.001	0.96	0.47	0.01	0.68	82

Pada tabel di atas memuat hasil pengukuran eror dengan menggunakan algoritma RNN yang diberikan optimasi RMSProp. Fokus penelitian akan diarahkan kepada performa eror menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 28 detik epoch 100, learning rate 0.01, MAE 0.57, MAPE 0.01, RMSE 0.75 dan R-Square dengan nilai 0.95. Perhitungan kinerja dengan R-Square tertinggi yaitu dengan nilai 0.96, epoch 200, learning rate 0.01, MAE 0.46, MAPE 0.01, RMSE 0.67 dan waktu 55 detik.

4.2.2 Model 2 dengan Algoritma LSTM

4.2.2.1 Hasil Model 2 LSTM Optimizer Adam

Hasil eksperimen dengan algoritma LSTM dan *optimizer* Adam serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.5 Hasil Model 2 LSTM Optimizer Adam

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	LSTM ADAM	100	0.1	0.95	0.59	0.01	0.75	84
2		100	0.01	0.94	0.63	0.01	0.86	51
3		100	0.001	0.92	0.74	0.01	0.97	51
4		200	0.1	0.96	0.47	0.01	0.66	99
5		200	0.01	0.91	0.88	0.02	1.02	99
6		200	0.001	0.96	0.51	0.01	0.66	101
7		300	0.1	0.96	0.46	0.01	0.65	152
8		300	0.01	0.93	0.74	0.01	0.88	150
9		300	0.001	0.96	0.50	0.01	0.71	203

Pada tabel di atas memuat hasil pengukuran eror dengan menggunakan algoritma LSTM yang diberikan optimasi Adam. Fokus penelitian akan diarahkan kepada performa eror menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 51 detik epoch 100, learning rate 0.01, MAE 0.63, MAPE 0.01, RMSE 0.86 dan R-Square dengan nilai 0.94. Perhitungan kinerja dengan R-Square tertinggi yaitu dengan nilai 0.95, epoch 100, learning rate 0.1, MAE 0.59, MAPE 0.01, RMSE 0.75 dan waktu 84 detik.

4.2.2.2 Hasil Model 2 LSTM Optimizer Adamax

Hasil eksperimen dengan algoritma LSTM dan *optimizer* Adamax serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.6 Hasil Model 2 LSTM Optimizer Adamax

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	LSTM ADAMAX	100	0.1	0.94	0.63	0.01	0.81	35
2		100	0.01	0.95	0.59	0.01	0.76	35
3		100	0.001	0.82	1.15	0.02	1.46	35
4		200	0.1	0.87	1.08	0.02	1.22	70
5		200	0.01	0.95	0.59	0.01	0.73	69
6		200	0.001	0.95	0.59	0.01	0.79	69
7		300	0.1	0.95	0.61	0.01	0.78	104
8		300	0.01	0.96	0.51	0.01	0.69	104
9		300	0.001	0.91	0.78	0.02	1.03	105

Pada tabel di atas memuat hasil pengukuran error dengan menggunakan algoritma LSTM yang diberikan optimasi Adamax. Fokus penelitian akan diarahkan kepada performa error menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 35 detik epoch 100, learning rate 0.01, MAE 0.59, MAPE 0.01, RMSE 0.76 dan R-Square dengan nilai 0.95. Perhitungan kinerja dengan R-Square tertinggi yaitu dengan nilai 0.96, epoch 300, learning rate 0.01, MAE 0.51, MAPE 0.01, RMSE 0.69 dan waktu 104 detik.

4.2.2.3 Hasil Model 2 LSTM Optimizer RMSProp

Hasil eksperimen dengan algoritma LSTM dan *optimizer* RMSProp serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.7 Hasil Model 2 LSTM Optimizer RMSProp

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	LSTM RMSPROP	100	0.1	0.94	0.62	0.01	0.80	36
2		100	0.01	0.96	0.52	0.01	0.68	36
3		100	0.001	0.92	0.73	0.01	0.96	42
4		200	0.1	0.96	0.50	0.01	0.72	74
5		200	0.01	0.97	0.46	0.01	0.63	72
6		200	0.001	0.96	0.48	0.01	0.68	83
7		300	0.1	0.96	0.49	0.01	0.71	108
8		300	0.01	0.95	0.60	0.01	0.75	108
9		300	0.001	0.96	0.50	0.01	0.68	110

Pada tabel di atas memuat hasil pengukuran eror dengan menggunakan algoritma LSTM yang diberikan optimasi RMSProp. Fokus penelitian akan diarahkan kepada performa eror menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 36 detik epoch 100, learning rate 0.01, MAE 0.52, MAPE 0.01, RMSE 0.68 dan R-Square dengan nilai 0.96. Perhitungan kinerja dengan R-Square tertinggi yaitu dengan nilai 0.97, epoch 200, learning rate 0.01, MAE 0.46, MAPE 0.01, RMSE 0.63 dan waktu 72 detik.

4.2.3 Model 3 dengan Algoritma GRU

4.2.3.1 Hasil Model 3 GRU Optimizer Adam

Hasil eksperimen dengan algoritma GRU dan *optimizer* Adam serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.8 Hasil Model 3 GRU Optimizer Adam

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	GRU ADAM	100	0.1	0.62	1.90	0.04	2.10	40
2		100	0.01	0.95	0.64	0.01	0.79	40
3		100	0.001	0.93	0.67	0.01	0.89	40
4		200	0.1	0.96	0.49	0.01	0.67	78
5		200	0.01	0.67	1.85	0.03	1.96	78
6		200	0.001	0.93	0.64	0.01	0.87	78
7		300	0.1	0.93	0.72	0.01	0.90	117
8		300	0.01	0.87	1.08	0.02	1.22	118
9		300	0.001	0.95	0.58	0.01	0.76	117

Pada tabel di atas memuat hasil pengukuran eror dengan menggunakan algoritma GRU yang diberikan optimasi Adam. Fokus penelitian akan diarahkan kepada performa eror menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 40 detik epoch 100, learning rate 0.01, MAE 0.64, MAPE 0.01, RMSE 0.79 dan R-Square dengan nilai 0.95. Perhitungan kinerja dengan R-Square tertinggi yaitu dengan nilai 0.96, epoch 200, learning rate 0.1, MAE 0.49, MAPE 0.01, RMSE 0.67 dan waktu 78 detik.

4.2.3.2 Hasil Model 3 GRU Optimizer Adamax

Hasil eksperimen dengan algoritma GRU dan *optimizer* Adamax serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.9 Hasil Model 3 GRU Optimizer Adamax

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	GRU ADAMAX	100	0.1	0.93	0.75	0.01	0.90	40
2		100	0.01	0.91	0.84	0.02	1.00	39
3		100	0.001	0.92	0.72	0.01	0.93	40
4		200	0.1	0.95	0.62	0.01	0.78	78
5		200	0.01	0.96	0.47	0.01	0.65	70
6		200	0.001	0.95	0.57	0.01	0.77	79
7		300	0.1	0.91	0.85	0.02	1.00	118
8		300	0.01	0.96	0.46	0.01	0.68	118
9		300	0.001	0.96	0.49	0.01	0.67	118

Pada tabel di atas memuat hasil pengukuran error dengan menggunakan algoritma GRU yang diberikan optimasi Adamax. Fokus penelitian akan diarahkan kepada performa error menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 39 detik epoch 100, learning rate 0.01, MAE 0.84, MAPE 0.02, RMSE 1.00 dan R-Square dengan nilai 0.91. Perhitungan kinerja dengan R-Square tertinggi yaitu dengan nilai 0.96, epoch 200, learning rate 0.01, MAE 0.47, MAPE 0.01, RMSE 0.65 dan waktu 70 detik.

4.2.3.3 Hasil Model 3 GRU Optimizer RMSProp

Hasil eksperimen dengan algoritma GRU dan *optimizer* RMSProp serta menggunakan *epoch* 100,200,300 dan *learning rate* 0.1, 0.001, 0.0001 dapat dilihat dalam tabel berikut :

Tabel 4.10 Hasil Model 3 GRU Optimizer RMSProp

No	Model / Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	GRU RMSPROP	100	0.1	0.95	0.55	0.01	0.74	42
2		100	0.01	0.96	0.51	0.01	0.68	41
3		100	0.001	0.96	0.51	0.01	0.69	41
4		200	0.1	0.96	0.49	0.01	0.72	82
5		200	0.01	0.96	0.46	0.01	0.70	81
6		200	0.001	0.96	0.53	0.01	0.71	82
7		300	0.1	0.95	0.52	0.01	0.72	122
8		300	0.01	0.96	0.46	0.01	0.65	122
9		300	0.001	0.95	0.59	0.01	0.77	121

Pada tabel di atas memuat hasil pengukuran error dengan menggunakan algoritma GRU yang diberikan optimasi RMSProp. Fokus penelitian akan diarahkan kepada performa error menggunakan R-Square atau koefisien determinasi mendekati 1 dan dengan waktu yang digunakan lebih cepat dalam proses komputasi. Perhitungan kinerja dengan waktu tercepat 41 detik epoch 100, learning rate 0.01, MAE 0.51, MAPE 0.01, RMSE 0.68 dan R-Square dengan nilai 0.96. Perhitungan kinerja ini termasuk kategori R-Square tertinggi untuk model algoritma GRU dengan *optimizer* RMSProp.

4.3 Evaluasi Metrik Performa Error

Dari berbagai eksperimen di atas setiap model algoritma akan dikumpulkan hasil dengan mempertimbangkan waktu penghitungan yang paling cepat dan nilai

error mendekati nol untuk MAE,MAPE dan RMSE serta nilai error mendekati 1 untuk Koefisien Determinasi (R-Square). Adapun nilai terbaik dari setiap model dapat dilihat pada tabel berikut :

Tabel 4.11 Kompilasi Metrik Performa Error

No	Model	Optimizer	Epoch	Learning Rate	R2	MAE	MAPE	RMSE	Waktu (detik)
1	RNN	Adam	100	0.01	0.96	0.53	0.01	0.70	26
2	RNN	Adam	300	0.1	0.97	0.44	0.01	0.62	83
3	RNN	Adamax	100	0.01	0.96	0.54	0.01	0.71	36
4	RNN	Adamax	200	0.01	0.97	0.45	0.01	0.63	73
5	RNN	RMSProp	100	0.01	0.95	0.57	0.01	0.75	28
6	RNN	RMSProp	200	0.001	0.96	0.46	0.01	0.67	55
7	LSTM	Adam	100	0.1	0.95	0.59	0.01	0.75	84
8	LSTM	Adam	100	0.01	0.94	0.63	0.01	0.86	51
9	LSTM	Adamax	100	0.01	0.95	0.59	0.01	0.76	35
10	LSTM	Adamax	300	0.01	0.96	0.51	0.01	0.69	104
11	LSTM	RMSProp	100	0.01	0.96	0.52	0.01	0.68	36
12	LSTM	RMSProp	200	0.01	0.97	0.46	0.01	0.63	72
13	GRU	Adam	100	0.01	0.95	0.64	0.01	0.79	40
14	GRU	Adam	200	0.1	0.96	0.49	0.01	0.67	78
15	GRU	Adamax	100	0.01	0.91	0.84	0.02	1.00	39
16	GRU	Adamax	200	0.01	0.96	0.47	0.01	0.65	70
17	GRU	RMSProp	100	0.01	0.96	0.51	0.01	0.68	41


4.4 Usulan Model Dengan Kinerja Terbaik

Dalam peramalan harga saham yang terpenting adalah semakin kecil tingkat error yang dicapai. Namun pertimbangan yang lain juga tidak kalah pentingnya adalah kecepatan komputasi untuk mencapai hasil prediksi yang terbaik. Untuk itu pertimbangan penelitian ini selain menitikberatkan pada tingkat error minimal, juga memperhatikan periode waktu

yang dibutuhkan dalam melakukan proses penghitungan model sehingga didapatkan hasil yang terbaik.

Penelitian ini telah mendapatkan 9 model terbaik dimana masing-masing algoritma diwakili oleh 1 *optimizer* yang terbaik. Koefisien determinasi rata-rata memiliki nilai di atas 0,95 hanya satu yang memiliki nilai 0,91 yaitu dengan model algoritma GRU dan optimizer Adamax. Waktu yang dibutuhkan untuk perhitungan model adalah 51 detik dan tercepat 26 detik. Kecepatan proses ini sebanding dengan banyaknya jumlah epoch yang digunakan yaitu 100,200,300 dengan jumlah batch size yang digunakan 16 batch.

Gambar 4.1 Grafik Kinerja Model Terbaik



Dalam hal ini usulan penelitian dengan model kinerja terbaik didapatkan hasil perhitungan dengan waktu tercepat 26 detik epoch 100, learning rate 0.01, MAE 0.53, MAPE 0.01, RMSE 0.70 dan R-Square dengan nilai 0.96. Perhitungan kinerja ini termasuk kategori R-Square paling tinggi untuk model algoritma RNN dengan optimizer Adam sebagaimana terlihat pada gambar berikut.

4.5 Impelementasi Aplikasi Prediksi Saham Bursa Efek Indonesia (BEI)

Model dengan kinerja terbaik apakah dapat diterapkan untuk prediksi saham di Bursa Efek Indonesia (BEI), tentunya melalui beberapa percobaan hal tersebut dapat terjawab. Untuk itu selanjutnya dikembangkan sebuah aplikasi sederhana dengan menggunakan data yang memiliki kapitalisasi pasar di atas Rp. 500 Milyar berdasarkan kategori fraksi harga sesuai Peraturan Nomor II-A tentang Perdagangan Efek Bersifat Ekuitas nomor Kep-00061/BEI/07-2021 tanggal 23 Juli

2021[6]. Setelah mendapatkan kode emiten maka kumpulan dataset diambil dari laman Yahoo Finance[25]. Daftar saham yang akan digunakan yaitu :

Tabel 4.12 Penerapan Model Untuk Saham Bursa Efek Indonesia

No	Kode	Market Cap (Rp)	Harga (Rp)	Kategori Fraksi Harga	Mulai Listing
1	ASII	204.4 T	5050	5	04-04-90
2	BRIS	87.9 T	2160	4	01-01-11
3	UNVR	153.7 T	4030	4	11-01-82
4	KLBF	75 T	1615	3	30-07-91
5	BBKP	16.3 T	500	3	10-07-06
6	MLPL	6.9 T	468	2	06-11-89
7	BABP	11.0 T	436	2	15-07-02
8	BHIT	7.0 T	95	1	24-11-97
9	FREN	38.8 T	126	1	29-11-06
10	ARTO	213.0 T	15525	5	12-01-16
11	BBRI	633.5 T	4110	4	10-11-03

Sumber : Pengolahan sendiri

Harga saham kurang dari Rp200,- (dua ratus rupiah) kategori 1, harga saham berada dalam rentang Rp200,- (dua ratus rupiah) sampai dengan kurang dari Rp500,- (lima ratus rupiah) kategori 2, harga saham berada dalam rentang Rp500,- (lima ratus rupiah) sampai dengan kurang dari Rp2.000,- (dua ribu rupiah) kategori 3, harga saham berada dalam rentang Rp2.000,- (dua ribu rupiah) sampai dengan kurang dari Rp5.000,- (lima ribu rupiah) kategori 4, harga saham Rp5.000,- (lima ribu rupiah) atau lebih, ditetapkan kategori 5. Dengan demikian klasifikasi harga saham yang termasuk kategori rendah pada fraksi harga 1 dan tertinggi pada fraksi harga 5.

Tabel 4.13 Hasil Pengujian Model Untuk Saham BEI

No	Kode Emiten	Fraksi Harga	R2	MAE	MAPE	RMSE	Waktu
1	ASII	5	0.96	78.63	0.01	96.83	83
2	BRIS	4	0.7	65.33	0.03	69.84	12
3	UNVR	4	0.97	201.02	0.04	247.94	47
4	KLBF	3	-0.7	17.03	0.01	21.76	8
5	BBKP	3	0.83	35.78	0.09	50.28	43
6	MLPL	2	0.97	24.04	0.1	38.82	83
7	BABP	2	0.95	14.72	0.07	28.64	49
8	BHIT	1	-9	20.45	0.23	57.64	84
9	FREN	1	-46	91.99	0.97	151.61	42
10	ARTO	5	-2.4	2174.3	0.14	2249.15	16
11	BBRI	4	0.98	61.14	0.02	82.23	44

Berdasarkan tabel pengujian di atas terhadap data saham BEI[26], model ini dapat digunakan untuk fraksi harga 2,4 dan 5, namun tidak dapat digunakan untuk fraksi harga dengan kategori 3. Saham yang dapat menggunakan model tersebut yaitu ASII (0.96), UNVR (0.97), MLPL (0.97), BABP (0.95) dan BBRI (0.98), sedangkan sisanya tidak dapat dilakukan prediksi menggunakan model tersebut.

BAB 5

PENUTUP

5.1. Kesimpulan

Setelah melalui berbagai pembahasan dan percobaan yang dilakukan akhirnya peneliti memberikan kesimpulan sebagai berikut :

1. Penggunaan algoritma neural network seperti RNN, LSTM, GRU sangat membantu dalam memecahkan masalah regresi terkait prediksi harga khususnya data yang bersifat sekuens / deret waktu seperti pada data saham.
2. *Preprocessing* data sangat membantu performa model menghasilkan eror seminimal mungkin seperti pengisian nilai yang kosong dengan nilai rata-rata harga saham sebelumnya. Pemilihan tipe skala data berupa *standar scaler* dapat meningkatkan kinerja daripada *minmax scaler*.
3. Perlunya pengaturan parameter agar dapat menghasilkan kinerja model sesuai dengan karakteristik data saham yang dilakukan penelitian.
4. Metrik performa eror yang terbaik mencapai *R Square* pada nilai 0,96 dengan arsitektur model yaitu :
 - Model neural network dengan input layer 4, 1 hidden layer dengan 32 neuron, output layer 1.
 - Parameter model dengan aktivasi input layer dan hiddel layer menggunakan ReLU, aktivasi output layer menggunakan sigmoid, jumlah epoch 100, dan batch size 16.
 - Optimasi terbaik memakai *optimizer* Adam dengan *learning rate* 0,01
5. Kinerja model yang diusulkan dalam penelitian ini dapat menghasilkan performa eror terkecil dengan menggunakan Algoritma RNN dibandingkan penelitian sebelumnya yaitu *R Square* 0.90[6].
6. Penerapan model yang dihasilkan dari penelitian ini telah dilakukan simulasi pada harga saham Bursa Efek Indonesia seperti dengan R-Square eror yaitu ASII (0.96), UNVR (0.97), MLPL (0.97), BABP (0.95) dan BBRI (0.98).

5.1. Saran

Terhadap penelitian ini masih dapat disempurnakan untuk mencari kinerja model yang lebih baik. Untuk itu beberapa saran yang dapat dilakukan yaitu :

1. Tingkat fluktuasi harga saham yang berbeda-beda diperlukan percobaan lebih lanjut dengan berbagai kombinasi parameter seperti jumlah batch size, epoch, aktivasi unit, dan parameter lainnya.
2. Penggunaan algoritma deep learning yang lain seperti Facebook Prophet dapat dilakukan untuk penelitian selanjutnya.
3. Penambahan rekayasa fitur terkait harga saham seperti teknikal saham, fundamental maupun analisis sentimen dapat dipertimbangkan untuk penelitian.

DAFTAR REFERENSI

- [1] “Yuk Nabung Saham,” *Bursa Efek Indonesia*, 2017.
<https://yuknabungsaham.idx.co.id/about-yns> (accessed Sep. 05, 2021).
- [2] P. Dey *et al.*, “Comparative Analysis of Recurrent Neural Networks in Stock Price Prediction for Different Frequency Domains,” *Algorithms*, vol. 14, no. 8, p. 251, Aug. 2021, doi: 10.3390/a14080251.
- [3] Y. Lin, S. Liu, H. Yang, and H. Wu, “Stock Trend Prediction Using Candlestick Charting and Ensemble Machine Learning Techniques With a Novelty Feature Engineering Scheme,” *IEEE Access*, vol. 9, pp. 101433–101446, 2021, doi: 10.1109/ACCESS.2021.3096825.
- [4] S. Ravikumar and P. Saraf, “Prediction of Stock Prices using Machine Learning (Regression, Classification) Algorithms,” in *2020 International Conference for Emerging Technology (INCET)*, Jun. 2020, pp. 1–5, doi: 10.1109/INCET49848.2020.9154061.
- [5] M. A. Istiaque Sunny, M. M. S. Maswood, and A. G. Alharbi, “Deep Learning-Based Stock Price Prediction Using LSTM and Bi-Directional LSTM Model,” in *2020 2nd Novel Intelligent and Leading Emerging Sciences Conference (NILES)*, Oct. 2020, pp. 87–92, doi: 10.1109/NILES50944.2020.9257950.
- [6] PT. Bursa Efek Indonesia, “Kep-00061/BEI/07-2021,” Jakarta, 2021.
[Online]. Available:
https://www.idx.co.id/media/10022/peraturan_ii_a_perdagangan_efek_bersifat_ekuitas.pdf.
- [7] “Support and Resistance Basics.”
<https://www.investopedia.com/trading/support-and-resistance-basics/>
(accessed Sep. 06, 2021).
- [8] Suyanto DR.ST.M.Sc, K. Nur Ramadhani S.T., M.T, and S. Mandala Ph.D, *Modernisasi Machine Learning Untuk Big Data*, 1st ed. Bandung: Informatika Bandung, 2019.
- [9] Y. Wang, W. Liao, and Y. Chang, “Gated Recurrent Unit Network-Based

- Short-Term Photovoltaic Forecasting,” *Energies*, vol. 11, no. 8, p. 2163, Aug. 2018, doi: 10.3390/en11082163.
- [10] B. Santosa and A. Umam, *Data Mining dan Big Data Analytics*, 2nd ed. Yogyakarta: Penebar Media Pustaka, 2018.
- [11] D. Chicco, M. J. Warrens, and G. Jurman, “The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation,” *PeerJ Comput. Sci.*, vol. 7, p. e623, Jul. 2021, doi: 10.7717/peerj-cs.623.
- [12] P. Yu and X. Yan, “Stock price prediction based on deep neural networks,” *Neural Comput. Appl.*, vol. 32, no. 6, pp. 1609–1628, Mar. 2020, doi: 10.1007/s00521-019-04212-x.
- [13] S. Dami and M. Esterabi, “Predicting stock returns of Tehran exchange using LSTM neural network and feature engineering technique,” *Multimed. Tools Appl.*, vol. 80, no. 13, pp. 19947–19970, May 2021, doi: 10.1007/s11042-021-10778-3.
- [14] Y. Gu, T. Shibukawa, Y. Kondo, S. Nagao, and S. Kamijo, “Prediction of Stock Performance Using Deep Neural Networks,” *Appl. Sci.*, vol. 10, no. 22, p. 8142, Nov. 2020, doi: 10.3390/app10228142.
- [15] O. B. Sezer, M. Ozbayoglu, and E. Dogdu, “A Deep Neural-Network Based Stock Trading System Based on Evolutionary Optimized Technical Analysis Parameters,” *Procedia Comput. Sci.*, vol. 114, pp. 473–480, 2017, doi: 10.1016/j.procs.2017.09.031.
- [16] Dini Indriyani Putri, Agung Budi Prasetyo, and Adian Fatchur Rochim, “Prediksi Harga Saham Menggunakan Metode Brown’s Weighted Exponential Moving Average dengan Optimasi Levenberg-Marquardt,” *J. Nas. Tek. Elektro dan Teknol. Inf.*, vol. 10, no. 1, pp. 11–18, Feb. 2021, doi: 10.22146/jnteti.v10i1.678.
- [17] P. C. S. Bezerra and P. H. M. Albuquerque, “Volatility forecasting via SVR–GARCH with mixture of Gaussian kernels,” *Comput. Manag. Sci.*, vol. 14, no. 2, pp. 179–196, Apr. 2017, doi: 10.1007/s10287-016-0267-0.
- [18] I. K. Nti, A. F. Adekoya, and B. A. Weyori, “A systematic review of fundamental and technical analysis of stock market predictions,” *Artif.*

- Intell. Rev.*, vol. 53, no. 4, pp. 3007–3057, Apr. 2020, doi: 10.1007/s10462-019-09754-z.
- [19] E. Ahmadi, M. Jasemi, L. Monplaisir, M. A. Nabavi, A. Mahmoodi, and P. Amini Jam, “New efficient hybrid candlestick technical analysis model for stock market timing on the basis of the Support Vector Machine and Heuristic Algorithms of Imperialist Competition and Genetic,” *Expert Syst. Appl.*, vol. 94, pp. 21–31, Mar. 2018, doi: 10.1016/j.eswa.2017.10.023.
 - [20] T.-H. Lu, Y.-C. Chen, and Y.-C. Hsu, “Trend definition or holding strategy: What determines the profitability of candlestick charting?,” *J. Bank. Financ.*, vol. 61, pp. 172–183, Dec. 2015, doi: 10.1016/j.jbankfin.2015.09.009.
 - [21] S. Chen, S. Bao, and Y. Zhou, “The predictive power of Japanese candlestick charting in Chinese stock market,” *Phys. A Stat. Mech. its Appl.*, vol. 457, pp. 148–165, Sep. 2016, doi: 10.1016/j.physa.2016.03.081.
 - [22] M. Zhu, S. Atri, and E. Yegen, “Are candlestick trading strategies effective in certain stocks with distinct features?,” *Pacific-Basin Financ. J.*, vol. 37, pp. 116–127, Apr. 2016, doi: 10.1016/j.pacfin.2015.10.007.
 - [23] K. Kumar and M. T. U. Haider, “Enhanced Prediction of Intra-day Stock Market Using Metaheuristic Optimization on RNN–LSTM Network,” *New Gener. Comput.*, vol. 39, no. 1, pp. 231–272, Apr. 2021, doi: 10.1007/s00354-020-00104-0.
 - [24] A. S. Saud and S. Shakya, “Analysis of look back period for stock price prediction with RNN variants: A case study on banking sector of NEPSE,” *Procedia Comput. Sci.*, vol. 167, pp. 788–798, 2020, doi: 10.1016/j.procs.2020.03.419.
 - [25] “Yahoo Finance.” <https://finance.yahoo.com/>.
 - [26] “Daftar Penerapan Saham BEI.” <https://github.com/nausya/tesis/tree/main/indosaham> (accessed Jan. 02, 2021).

DAFTAR RIWAYAT HIDUP

A. Biodata Mahasiswa

NIM : 14002432
 Nama Lengkap : Dwi Andriyanto
 Tempat, Tanggal Lahir : Kebumen, 25 Januari 1979
 Alamat Lengkap : Jl. Warga RT.12/06 No. 41 Pondok Ranggon, Cipayung,
 Jakarta Timur

B. Riwayat Pendidikan Formal & Non Formal

Pendidikan Formal

1. SD Negeri Bumirejo V, Lulus Tahun 1991
2. SMP Negeri I Kebumen, Lulus Tahun 1994
3. SMU Negeri I Kebumen, Lulus Tahun 1997
4. Sekolah Tinggi Akuntansi Negara Jakarta, Lulus Tahun 2000
5. Universitas Terbuka, Lulus Tahun 2008

Pendidikan Non Formal (Training)

1. E-Learning Information Security Awareness, 2020
2. Workshop Aplikasi Tableau, 2020
3. Workshop Application Performance Monitoring (APM), 2020
4. Online Academy Training Javascript, 2020
5. Workshop E-Government Essentials, 2020
6. Denodo Webinar Series, 2021
7. Kemenkeu Kelas Data Analitik, 2021

C. Pengalaman Bekerja

1. Kanwil XII DJP Ujungpandang (2000 – 2004) – Pelaksana
2. Direktorat Informasi Perpajakan (2004-2009) – Pelaksana
3. Direktorat Teknologi Informasi Perpajakan (2009-2016) – Pelaksana
4. Kantor Pelayanan Pajak Pratama Jakarta Tanjung Priok (2016-2019) – Account Representative

1. Direktorat Teknologi Informasi dan Komunikasi (2019-sekarang) Fungsional
Pranata Komputer Muda

D. Kemampuan

1. Software

Windows, Linux, Microsoft Office, Open Office

2. Bahasa Pemrograman & Database

PHP, JAVA, Python, Oracle, MySQL



Jakarta, Januari 2022

Dwi Andriyanto

	LEMBAR BIMBINGAN TESIS
	UNIVERSITAS NUSA MANDIRI

NIM : 14002432
 Nama : Dwi Andriyanto
 Dosen Pembimbing : Dr. Yan Riyanto M.Eng.
 Judul Tesis : Optimasi *Deep Neural Network* Untuk Prediksi Harga Saham Dengan Fluktuasi Menengah

No	Tanggal Bimbingan	Materi Bimbingan	Paraf Dosen Pembimbing
1	27 September 2021	Paparan awal draft proposal	
2	12 Oktober 2021	Perbaikan rujukan paper utama terkait dataset yang digunakan	
3	26 Oktober 2021	Penyampaian hasil eksperimen atas dataset paper acuan utama	
4	22 November 2021	Perbaikan eksperimen lanjutan agar dicoba untuk saham BEI	
5	30 November 2021	Paparan penerapan metode untuk saham BEI	
6	13 Desember 2021	Eksperimen dengan tuning optimiser, learning rate dan epoch	
7	17 Desember 2021	Penyampaian Bab 1 dan Bab 2	
8	19 Desember 2021	Melengkapi Bab 1 dengan jurnal terbitan IEEE	
9	20 Desember 2021	Penyampaian revisi Bab 1 dan Bab 2	
10	04 Januari 2022	Penyampaian Seluruh Tesis	

Bimbingan Tesis

- Dimulai pada tanggal : 27 September 2021
- Diakhiri pada tanggal : 04 Januari 2022
- Jumlah pertemuan bimbingan : 10 (Sepuluh) kali pertemuan

Disetujui oleh,
Dosen Pembimbing

Dr. Yan Riyanto M.Eng.

LAMPIRAN KODE

```
#Impor Library
import pandas as pd
import numpy as np
%matplotlib inline
import matplotlib.pyplot as plt
import matplotlib
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import StandardScaler
from tensorflow.keras.layers import LSTM, SimpleRNN, GRU, Dense, Dropout
from sklearn.model_selection import TimeSeriesSplit
import matplotlib.dates as mandates
from sklearn import linear_model
from keras.models import Sequential
import keras.backend as K
from keras.callbacks import EarlyStopping
from keras import optimizers
from tensorflow.keras.optimizers import Adamax, Adam, RMSprop
from keras.models import load_model
from keras.utils.vis_utils import plot_model
import timeit
from sklearn.metrics import make_scorer, r2_score, confusion_matrix,
mean_squared_error
from sklearn import metrics
from math import sqrt

# Tampilan layar
pd.set_option('display.max_rows', 800)
pd.set_option('display.max_columns', 500)

#Ambil Data
df =
pd.read_csv("orcl.csv", index_col='Date', parse_dates=True, infer_datetime_format=True)
df.to_pickle('dataset.pkl')
df = pd.read_pickle('dataset.pkl')
df.info()

#Interval 5 hari
agg_dict = {'Open': 'first',
            'High': 'max',
            'Low': 'min',
            'Close': 'last',
            'Adj Close': 'last',
            'Volume': 'mean'}

# re-sample dataframe
# 'D' untuk aggregat harian
df = df.resample('5D').agg(agg_dict)
```

```

#Print cek data kosong
print("Dataframe Shape: ", df. shape)
print("Null Value Present: ", df.isnull().values.any())

#pengisian data kosong
df = df.fillna(method = "ffill")

#Plot Nilai Close
df["Close"].plot()

#Tentukan Target
output_var = pd.DataFrame(df['Close'])
#Pilih Features
features = ['Open', 'High', 'Low', 'Volume']

#Skala Data
scaler = StandardScaler()# standar scaler lebih baik
#scaler = MinMaxScaler()
feature_transform = scaler.fit_transform(df[features])
feature_transform= pd.DataFrame(columns=features, data=feature_transform,
index=df.index)
feature_transform.head()

#Split Data Train set and Test set
timesplit= TimeSeriesSplit(n_splits=10)
for train_index, test_index in timesplit.split(feature_transform):
    X_train, X_test = feature_transform[:len(train_index)],
    feature_transform[len(train_index): (len(train_index)+len(test_index))]
    y_train, y_test = output_var[:len(train_index)].values.ravel(),
    output_var[len(train_index): (len(train_index)+len(test_index))].values.ravel()

#Reshape Data
trainX =np.array(X_train)
testX =np.array(X_test)
X_train = trainX.reshape(X_train.shape[0], 1, X_train.shape[1])
X_test = testX.reshape(X_test.shape[0], 1, X_test.shape[1])

#Rencana Model

jml_epochs= 100
input_optimasi = 'Adam'
input_lr = '01'

#Set optimizer
if input_lr == '01':
    lr=0.1
elif input_lr == '001':
    lr=0.01
elif input_lr == '0001':
    lr=0.001

if input_optimasi == 'Adamax':
    opt = Adamax(learning_rate=lr)

```

```

elif input_optimasi == 'Adam':
    opt = Adam(learning_rate=lr)
elif input_optimasi == 'RMSprop':
    opt = RMSprop(learning_rate=lr)

model = Sequential()
model.add(SimpleRNN(32, input_dim=len(features), activation='relu',
kernel_initializer='he_normal'))
model.add(Dense(1, activation='linear'))
model.compile(loss='mean_squared_error', optimizer=opt, metrics=['mae','mse'])

model.summary()

#Model Training
#waktu
start = timeit.default_timer()
history=model.fit(X_train, y_train, epochs=jml_epochs, batch_size=16, verbose=1,
shuffle=False)
stop = timeit.default_timer()

#Model Prediksi
y_pred= model.predict(X_test)

#Print Metrik Error
print ('R Squared =',r2_score(y_test, y_pred))
ORCL_R2_MODEL = r2_score(y_test, y_pred)

print('Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_pred))
ORCL_MAE_MODEL = metrics.mean_absolute_error(y_test, y_pred)

print('Mean Absolute Percentage Error:', metrics.mean_absolute_percentage_error(y_test,
y_pred))
ORCL_MAPE_MODEL = metrics.mean_absolute_percentage_error(y_test, y_pred)

print('Root Mean Squared Error:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))
ORCL_RMSE_MODEL = np.sqrt(metrics.mean_squared_error(y_test, y_pred))

#Kompilasi Performa Error
from prettytable import PrettyTable
waktu = stop - start
nmtabel =
PrettyTable(["Model", "Epoch", "LR", "OPT", "R2", "MAE", "MAPE", "RMSE", "Waktu"])
nmtabel.add_row(["RNN", jml_epochs, input_lr, input_optimasi, '{:.2f}'.format(ORCL_R2
_MODEL), '{:.2f}'.format(ORCL_MAE_MODEL),
'{:.2f}'.format(ORCL_MAPE_MODEL),
'{:.2f}'.format(ORCL_RMSE_MODEL), '{:.0f}'.format(waktu)])
print(nmtabel)

#Grafik Asli dan Prediksi
plt.plot(y_test, label='asli')
plt.plot(y_pred, label='prediksi')
plt.title("Prediksi Harga Saham")
plt.xlabel('Waktu')

```

```
plt.ylabel('USD')  
plt.legend()  
plt.show()  
  
#Hapus Sesi  
K.clear_session()
```